UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO

FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y MECÁNICA

ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



PLAN DE TESIS

Análisis de patrones espacio-temporales de las ocurrencias de seguridad ciudadana mediante técnicas de agrupamiento espacial en el distrito de San Sebastián, Cusco, periodo enero-agosto de 2025

Para optar al título profesional de:
Ingeniero Informático y de Sistemas

Presentado por:
Br. Ronaldo Ticona Jancco

Asesor:
Por designar

CUSCO – PERÚ
2026

RESUMEN

El presente estudio analiza la distribución espacial y temporal de 996 registros de ocurrencias de seguridad ciudadana en San Sebastián (Cusco), correspondientes a un extracto de la capa SIPCOP Municipal entre el 1 de enero y el 29 de agosto de 2025. Un diagnóstico preliminar muestra que las coordenadas (`x`, `y`) están en grados decimales con tres decimales (resolución de unos 110 m), por lo que el extracto contiene solo 412 ubicaciones distintas, y que la tasa diaria de registros varía de 2,0 (junio) a 7,5 (agosto). Este plan propone analizar la distribución espacial y temporal de las ocurrencias con DBSCAN (radios de 150 a 300 m) y HDBSCAN como comparación, y contrastar los grupos frente a la aleatoriedad espacial completa y frente a un segundo modelo nulo restringido al área urbanizada. La distribución por turno, día de la semana y mes de los grupos significativos se comparará con la del resto del distrito mediante chi-cuadrado de homogeneidad o permutación, y la exposición calendario se usará como análisis secundario. Se realizarán análisis de sensibilidad según el origen del registro (patrullaje o llamada ciudadana) y el tipo de ocurrencia. El estudio es cuantitativo, descriptivo, inferencial y observacional; sus conclusiones se limitan a este extracto y no representan años o meses fuera de su cobertura.

Palabras clave: ocurrencias de seguridad ciudadana, agrupamiento espacial, DBSCAN, *hotspots*, patrullaje municipal, San Sebastián.

ABSTRACT

The present study analyses the spatial and temporal distribution of 996 public security incident records in San Sebastián (Cusco), corresponding to an extract of the SIPCOP Municipal layer between 1 January and 29 August 2025. A preliminary diagnosis shows that coordinates (x, y) are decimal degrees with three decimals (about 110 m resolution), so the extract holds only 412 distinct locations, and that the daily record rate ranges from 2.0 (June) to 7.5 (August). This proposal plans to analyse the spatial and temporal distribution of incidents with DBSCAN (radii of 150 to 300 m), using HDBSCAN as a comparison, and to test the clusters against complete spatial randomness and against a second null model restricted to the built-up area. The distribution by shift, day of the week and month of the significant clusters will be compared with that of the rest of the district using a chi-square test of homogeneity or a permutation test, with calendar exposure as a secondary analysis. Sensitivity analyses will consider the record origin (patrol or citizen call) and the incident type. The study is quantitative, descriptive, inferential and observational; its conclusions are limited to this extract and do not represent years or months outside its coverage.

Keywords: public security incidents, spatial clustering, DBSCAN, hotspots, municipal patrol, San Sebastián.

AGRADECIMIENTOS

Agradezco a quienes apoyaron el desarrollo de esta investigación: a la Universidad Nacional de San Antonio Abad del Cusco y a la Escuela Profesional de Ingeniería Informática y de Sistemas, por mi formación; a los docentes que orientaron la elaboración de este plan; y a mi familia, por su respaldo constante.

ÍNDICE GENERAL

Resumen I

Abstract II

Agradecimientos III

Índice de figuras VIII

Índice de tablas IX

Índice de algoritmos X

Índice de ecuaciones XI

Índice de anexos XII

Índice de abreviaturas XIII

Índice de símbolos XIV

Glosario de términos XV

Introducción XVI

Capítulo I Generalidades 1

1.1 Planteamiento del problema 1

1.1.1 Descripción del problema 1

1.1.2 Identificación del problema 2

1.1.3 Formulación del problema 2

1.1.3.1 Problema general 2

1.1.3.2 Problemas específicos 2

1.2 Objetivos de la investigación 2

1.2.1 Objetivo general 2

1.2.2 Objetivos específicos 3

1.3 Hipótesis de la investigación 3

1.3.1 Hipótesis general 3

1.3.2 Hipótesis específicas 3
1.4 Justificación de la investigación 4
1.5 Alcances y limitaciones 4
1.5.1 Alcances 4
1.5.2 Limitaciones 5
Capítulo II Marco teórico y estado del arte **7**
2.1 Antecedentes y estado del arte 7
2.1.1 Antecedentes internacionales 7
2.1.2 Antecedentes nacionales 7
2.1.3 Antecedentes locales 8
2.1.4 Síntesis y brecha de investigación 8
2.2 Fundamentos teóricos 9
2.2.1 Seguridad ciudadana y concentración del delito 9
2.2.2 Análisis espacial 9
2.2.3 Agrupamiento espacial por densidad 10
2.2.4 Resolución y error de georreferenciación 10
2.2.5 Inferencia sobre concentraciones espaciales y espacio-temporales . 11
2.2.6 Evaluación de la calidad del agrupamiento 11
2.2.7 Análisis temporal y pruebas estadísticas 11
2.2.8 Visualización geoespacial 12
2.3 Definición de términos básicos 12
Capítulo III Metodología de la investigación **13**
3.1 Enfoque, tipo y diseño de investigación 13
3.1.1 Enfoque de investigación 13
3.1.2 Tipo y alcance de la investigación 13
3.1.3 Diseño de investigación 13
3.2 Definiciones y variables 14
3.2.1 Definiciones operativas 14
3.2.2 Variables y operacionalización 14

3.3 Unidad de análisis, población y muestra 15
3.3.1 Unidad de análisis 15
3.3.2 Población y muestra 15
3.3.3 Diagnóstico preliminar del extracto 16
3.4 Técnicas e instrumentos de recolección 18
3.5 Procedimiento metodológico 18
3.6 Protocolo de evaluación 20
3.6.1 Selección de parámetros y calidad del agrupamiento 20
3.6.2 Comparación entre DBSCAN y HDBSCAN 20
3.6.3 Concentración espacial frente al azar 21
3.6.4 Distribución temporal de los *hotspots* 21
3.6.5 Análisis de sensibilidad 23
3.7 Métodos de análisis de datos 23
3.8 Aspectos éticos y de gestión de datos 23

Capítulo IV Estudio de factibilidad **24**

4.1 Enfoque adoptado 24
4.2 Factibilidad técnica 24
4.2.1 Hardware y cómputo 24
4.2.2 Datos 24
4.2.3 Herramientas y software 25
4.3 Factibilidad económica 25
4.4 Factibilidad operativa 25
4.5 Viabilidad y sostenibilidad 25

Capítulo V Aspectos administrativos **26**

5.1 Cronograma de actividades 26
5.2 Presupuesto y financiamiento 26
5.3 Equipo de investigación 27

Referencias **28**

Anexo 1. Matriz de consistencia **31**

Anexo 2. Ficha de estructura de datos del SIPCOP-M **32**

Anexo 3. Registro de depuración de datos **33**

ÍNDICE DE FIGURAS

Figura 1. Etapas del procedimiento metodológico. 13

Figura 2. Ubicaciones distintas del extracto SIPCOP Municipal (San Sebastián, 2025). 17

Figura 3. Volumen de registro y modalidad de exposición a peligro o abandono por mes. 17

ÍNDICE DE TABLAS

Tabla 1. Síntesis de los antecedentes revisados. 9

Tabla 2. Operacionalización de los resultados medidos. 15

Tabla 3. Diagnóstico preliminar del extracto SIPCOP Municipal de San Sebastián. 16

Tabla 4. Cronograma de actividades por semanas (octubre 2026 – febrero 2027). 26

Tabla 5. Presupuesto estimado del proyecto (soles). 27

Tabla 6. Equipo de investigación. 27

Tabla 7. Matriz de consistencia. 31

Tabla 8. Campos del archivo CSV SIPCOP Municipal (19 columnas). 32

Tabla 9. Registro de depuración preliminar. 33

ÍNDICE DE ALGORITMOS

1 DBSCAN aplicado a las ocurrencias georreferenciadas. 19

ÍNDICE DE ECUACIONES

1 Distancia haversine entre dos ocurrencias. 10

2 Estimador de densidad kernel. 10

3 Vecindad ε de un punto en DBSCAN. 10

4 Coeficiente de silueta. 11

5 Estadístico chi-cuadrado de Pearson. 11

6 Valor p Monte Carlo de un grupo espacial. 21

7 Coeficiente V de Cramér. 22

ÍNDICE DE ANEXOS

1 Matriz de consistencia 31

2 Ficha de estructura de datos del SIPCOP-M 32

3 Registro de depuración de datos 33

ÍNDICE DE ABREVIATURAS

ARI	*Adjusted Rand Index* (índice de Rand ajustado).
CRISP-DM	*Cross-Industry Standard Process for Data Mining*.
CSR	*Complete Spatial Randomness* (aleatoriedad espacial completa).
DBSCAN	*Density-Based Spatial Clustering of Applications with Noise*.
ENAPRES	Encuesta Nacional de Programas Presupuestales.
GIS	*Geographic Information System* (equivalente en inglés de SIG).
HDBSCAN	*Hierarchical Density-Based Spatial Clustering of Applications with Noise*.
INEI	Instituto Nacional de Estadística e Informática.
KDE	*Kernel Density Estimation* (estimación de densidad kernel).
PNP	Policía Nacional del Perú.
SIG	Sistema de Información Geográfica.
SIPCOP-M	Sistema de registro de las ocurrencias de seguridad atendidas por el serenazgo de la Municipalidad Distrital de San Sebastián.
UNSAAC	Universidad Nacional de San Antonio Abad del Cusco.
UTM	*Universal Transverse Mercator*.
WGS84	*World Geodetic System 1984*.

ÍNDICE DE SÍMBOLOS

ε	Radio de vecindad de DBSCAN (distancia máxima entre dos puntos vecinos).
MinPts	Número mínimo de puntos dentro del radio ε para considerar un punto como núcleo.
$N_\varepsilon(p)$	Conjunto de puntos a distancia menor o igual que ε del punto p.
$d(p,q)$	Distancia entre los puntos p y q.
R	Radio medio de la Tierra (aprox. 6371 km).
$\varphi,\ \lambda$	Latitud y longitud, respectivamente, expresadas en radianes.
h	Ancho de banda (*bandwidth*) del estimador de densidad kernel.
$K(\cdot)$	Función kernel.
$\hat{f}(x)$	Densidad estimada de incidentes en la ubicación x.
χ^2	Estadístico chi-cuadrado de Pearson.
$O_i,\ E_i$	Frecuencia observada y esperada de la categoría i.
$H_0,\ H_1$	Hipótesis nula y alterna.
α	Nivel de significancia.
$s(i)$	Coeficiente de silueta del punto i.
$a(i),\ b(i)$	Distancia media del punto i a los de su grupo y al grupo vecino más cercano.
V	Coeficiente V de Cramér (tamaño del efecto).
B	Número de simulaciones Monte Carlo.
m_j	Número de ocurrencias del grupo espacial j.
M_b	Tamaño del mayor grupo en la simulación b.
p_j	Valor p Monte Carlo del grupo j.

GLOSARIO DE TÉRMINOS

Agrupamiento espacial	Técnica de análisis que reúne eventos geográficamente cercanos en grupos (*clusters*) según un criterio de proximidad o densidad.
Densidad kernel	Método que estima una superficie continua de intensidad de eventos a partir de puntos, ponderando cada evento según su distancia.
Epsilon (ε)	Parámetro de DBSCAN que define el radio de búsqueda de vecinos alrededor de un punto.
Georreferenciación	Asignación de coordenadas geográficas a un registro para ubicarlo en un sistema de referencia espacial.
Haversine	Fórmula que calcula la distancia sobre una esfera entre dos puntos dados por latitud y longitud.
Grupo espacial (clúster)	Conjunto de ocurrencias que un algoritmo de agrupamiento reúne por su proximidad o densidad.
Hotspot	Grupo espacial cuyo número de ocurrencias supera lo esperado bajo aleatoriedad espacial completa, según un contraste estadístico.
Ocurrencia de seguridad ciudadana	Hecho de seguridad atendido y registrado por el serenazgo; incluye hechos que no son necesariamente delitos.
Mapa de calor	Representación cartográfica que usa gradientes de color para mostrar la intensidad de un fenómeno.
MinPts	Parámetro de DBSCAN que fija el mínimo de puntos requeridos en la vecindad para formar un grupo.
Patrón espacio-temporal	Regularidad en la distribución geográfica y en el momento de ocurrencia (turno, día, mes) de los eventos.
Ruido	Puntos que DBSCAN no asigna a ningún grupo por estar en zonas de baja densidad.
Serenazgo	Servicio municipal de seguridad ciudadana que realiza patrullaje y prevención en el distrito.
Turno	Franja horaria de operación del serenazgo (por ejemplo, mañana, tarde o noche).

INTRODUCCIÓN

La seguridad ciudadana es una de las principales demandas de la población peruana y una responsabilidad de gestión de los gobiernos locales. En la región Cusco, los registros de la Policía Nacional del Perú muestran un aumento de las denuncias por homicidio, y la Encuesta Nacional de Programas Presupuestales (ENAPRES) sitúa al departamento entre los de mayor percepción de inseguridad del país (Instituto Nacional de Estadística e Informática, 2023). Sin embargo, los hechos no se distribuyen de manera uniforme: tienden a concentrarse en ciertos lugares y momentos (Eck et al., 2005; Chainey and Ratcliffe, 2005; Weisburd, 2015), de modo que gestionarlos exige decidir dónde y cuándo intervenir, y no solo con qué recursos.

Para estudiar esa concentración se emplean mapas de calor, estimación de densidad kernel y técnicas de agrupamiento espacial (Chainey and Ratcliffe, 2005; Chainey et al., 2008). DBSCAN (Ester et al., 1996) agrupa las ocurrencias según su densidad, no exige fijar el número de grupos y deja como ruido los puntos aislados; HDBSCAN (Campello et al., 2013) extiende la idea a una jerarquía de densidades. Ambos dependen de parámetros cuya elección condiciona los grupos obtenidos, por lo que deben justificarse y verificarse (Schubert et al., 2017). Además, que un algoritmo devuelva un grupo no demuestra que su concentración supere lo esperable por azar, y esa distinción es central en este plan.

El método ya se ha aplicado en el Perú (Cutid-Aguero et al., 2025), pero no se dispone de un análisis documentado de las ocurrencias registradas por el patrullaje municipal e integrado de San Sebastián: el SIPCOP-M las conserva como registros tabulares. Esta brecha es provisional y se contrasta con la revisión del Capítulo II.

Por ello se propone analizar la distribución espacial y temporal de las 996 ocurrencias contenidas en el extracto disponible de SIPCOP Municipal, con fechas de alerta entre el 1 de enero y el 29 de agosto de 2025. El estudio evaluará la calidad de los registros, detectará grupos espaciales con DBSCAN (comparado con HDBSCAN), contrastará cuáles superan lo esperado por azar y examinará su distribución por turno, día de la semana y mes con pruebas

chi-cuadrado. Un diagnóstico preliminar del archivo indica que las coordenadas son grados decimales con resolución de unos 110 m (412 ubicaciones distintas en 996 registros), lo que condiciona el radio de agrupamiento, y que la tasa de registros cambia mucho entre meses, lo que condiciona la referencia temporal. La fecha de alerta no se asumirá como fecha exacta del hecho sin confirmar su definición. El propósito es producir evidencia acotada a este extracto para apoyar la focalización del patrullaje, sin presuponer que los patrones existan. El estudio es cuantitativo, descriptivo, inferencial y observacional.

El plan se organiza en cinco capítulos: Generalidades (I), Marco teórico y estado del arte (II), Metodología (III), Estudio de factibilidad (IV) y Aspectos administrativos (V). Al final se incluyen las referencias y los anexos.

CAPÍTULO I

GENERALIDADES

1.1. Planteamiento del problema

1.1.1. Descripción del problema

La región Cusco enfrenta un incremento sostenido en la percepción de inseguridad ciudadana y en la ocurrencia de hechos delictivos. Según registros de la Policía Nacional del Perú, las denuncias por homicidio en el departamento de Cusco aumentaron de 36 casos en 2022 a 60 casos en 2024 (enero-noviembre) (Policía Nacional del Perú, 2024). Asimismo, la Encuesta Nacional de Programas Presupuestales (ENAPRES) ubicó a Cusco entre los departamentos con mayor porcentaje de percepción de inseguridad del país, con un 92,3 % durante el periodo noviembre 2022-abril 2023 (Instituto Nacional de Estadística e Informática, 2023).

La literatura criminológica documenta que el delito no se reparte al azar: una proporción reducida de lugares concentra una parte desproporcionada de los hechos (Sherman et al., 1989; Weisburd, 2015). Por ello, los gobiernos locales, que participan en el Sistema Nacional de Seguridad Ciudadana a través de los comités distritales (Congreso de la República del Perú, 2003), necesitan saber en qué zonas y en qué momentos se concentran los incidentes para orientar el patrullaje.

El Mapa del Delito Georreferenciado del Ministerio del Interior publica una capa denominada SIPCOP Municipal con registros de ocurrencias del patrullaje municipal e integrado (serenazgo y patrullaje local integrado). El extracto disponible para el distrito de San Sebastián contiene 996 registros entre el 1 de enero y el 29 de agosto de 2025, con categoría, turno y coordenadas. Aún no se ha documentado un análisis local que caracterice su distribución espacial y temporal. El campo temporal disponible es la fecha de alerta; no se cuenta con hora individual en el archivo descargado. Las coordenadas están en grados decimales con tres decimales (unos 110 m), de modo que los 996 registros se reducen a 412

ubicaciones distintas.

1.1.2. Identificación del problema

La principal dificultad es que el extracto público de SIPCOP Municipal aún no se ha transformado en información espacial y temporal útil para la gestión local. Se requiere evaluar la calidad de sus 996 registros y establecer si existen concentraciones espaciales y diferencias de recurrencia por turno, día de la semana y mes. El periodo disponible cubre enero-agosto de 2025 y no representa los años 2022-2024 ni los últimos meses de 2025.

1.1.3. Formulación del problema

1.1.3.1. Problema general

¿Cuáles son los patrones de distribución espacial y temporal de las ocurrencias registradas en la capa SIPCOP Municipal para el distrito de San Sebastián, Cusco, entre el 1 de enero y el 29 de agosto de 2025?

1.1.3.2. Problemas específicos

PE1. ¿Qué proporción de las ocurrencias registradas en el SIPCOP-M cuenta con ubicación, fecha y tipo de ocurrencia utilizables, y con qué resolución espacial y convención de georreferenciación están registradas?

PE2. ¿Qué concentraciones espaciales de ocurrencias se detectan con DBSCAN, cuáles de ellas superan lo esperado por azar y en qué medida coincide HDBSCAN?

PE3. ¿Cómo se distribuyen en el tiempo (turno, día de la semana, mes) las ocurrencias de las concentraciones significativas y difiere esa distribución de la esperada por exposición?

1.2. Objetivos de la investigación

1.2.1. Objetivo general

Analizar la distribución espacial y temporal de las ocurrencias registradas en la capa SIPCOP Municipal para el distrito de San Sebastián, Cusco, entre el 1 de enero y el 29 de

agosto de 2025, mediante técnicas de agrupamiento espacial y procedimientos estadísticos, considerando la calidad y las limitaciones del extracto disponible.

1.2.2. Objetivos específicos

OE1. Evaluar la calidad y cobertura de los registros del SIPCOP-M, determinar la proporción de ocurrencias utilizables y caracterizar la resolución espacial y la convención de georreferenciación de las coordenadas.

OE2. Identificar y caracterizar las concentraciones espaciales de ocurrencias mediante DBSCAN, contrastarlas frente a la aleatoriedad espacial y comparar sus resultados con HDBSCAN.

OE3. Analizar la distribución temporal (turno, día de la semana y mes) de las ocurrencias de las concentraciones significativas, mediante procedimientos estadísticos adecuados.

1.3. Hipótesis de la investigación

1.3.1. Hipótesis general

H_G: Las ocurrencias registradas en SIPCOP Municipal para San Sebastián entre el 1 de enero y el 29 de agosto de 2025 presentan (a) concentraciones espaciales que superan la aleatoriedad espacial completa (H_1) y (b) en esas concentraciones, una distribución por turno, día de la semana o mes distinta de la del resto del distrito (H_2). Cada componente se contrasta y se informa por separado, aunque el otro no se sostenga.

1.3.2. Hipótesis específicas

H_1: Al menos un grupo espacial detectado con DBSCAN concentra más ocurrencias que las esperadas bajo aleatoriedad espacial completa (objetivo específico 2). Los grupos que superan este contraste se denominan *hotspots*.

H_2: En los *hotspots*, la distribución de las ocurrencias por turno, día de la semana o mes difiere de la del resto del distrito (objetivo específico 3). La hipótesis nula establece que ambas distribuciones coinciden; $\alpha = 0{,}05$. La esperada por exposición calendario se usa como contraste secundario.

El objetivo específico 1 es descriptivo y no se contrasta con una hipótesis.

1.4. Justificación de la investigación

Justificación científica. La investigación aportará evidencia empírica sobre la distribución espacial y temporal de las ocurrencias de seguridad en un distrito de la región Cusco, contrastando si estas se concentran en determinados lugares y momentos o se distribuyen al azar.

Justificación metodológica. El estudio establece un procedimiento reproducible que integra la depuración y georreferenciación de registros, el agrupamiento espacial con parámetros justificados y el contraste estadístico de la recurrencia temporal, con criterios explícitos de calidad y de significancia.

Justificación tecnológica. Los resultados permitirán conocer las capacidades y limitaciones de DBSCAN y de HDBSCAN aplicados a registros del SIPCOP-M y convertir datos tabulares en información geoespacial útil para el patrullaje municipal.

Justificación social y práctica. La Municipalidad Distrital dispondrá de información sobre zonas críticas y momentos de mayor recurrencia para focalizar el patrullaje y la prevención del serenazgo. El estudio no mide el efecto de ninguna intervención sobre la reducción del delito.

1.5. Alcances y limitaciones

1.5.1. Alcances

Alcance espacial. Distrito de San Sebastián, provincia y departamento de Cusco.

Alcance temporal. Registros con fecha de alerta entre el 1 de enero y el 29 de agosto de 2025, según el extracto disponible al preparar el estudio.

Alcance tecnológico. Depuración y georreferenciación de los registros del SIPCOP-M; agrupamiento con DBSCAN y comparación con HDBSCAN; contraste frente a aleatoriedad espacial; estimación de densidad kernel solo como visualización; contraste temporal mediante chi-cuadrado.

Alcance disciplinar. Ciencia de datos y análisis geoespacial, dentro de la Ingeniería

Informática y de Sistemas.

1.5.2. Limitaciones

Calidad y cobertura del registro. El análisis se limita a 996 filas del extracto público descargado. Se evaluarán coordenadas, categorías, duplicados y otros problemas de calidad; los resultados no cubren registros no incluidos en ese extracto. El archivo no trae un identificador único de ocurrencia, por lo que los duplicados no pueden confirmarse, y todos los registros pertenecen a un mismo genérico (alertas tempranas en apoyo a la PNP), por lo que el extracto parece ser un subconjunto de la actividad total.

Resolución espacial. Las coordenadas tienen tres decimales (unos 110 m): hay 412 ubicaciones distintas y el 77 % de los registros comparte coordenada exacta con otro. Es probable que parte de las ubicaciones proceda de una geocodificación por puntos de referencia (por ejemplo, paraderos o el cementerio) y no de la posición real del hecho; los resultados no se interpretarán a escalas menores que esa resolución.

Estabilidad del registro en el tiempo. Los registros por día varían de 2,0 (junio) a 7,5 (agosto); hay 26 de 241 días sin ningún registro (no se sabe si hubo cero eventos o falta de reporte) y la modalidad de "exposición a peligro o abandono de personas" pasa del 57 % de los registros en enero a 9–17 % de junio a agosto, lo que sugiere un cambio de clasificación o de práctica de registro. Las diferencias entre meses pueden reflejar el registro y no el fenómeno.

Cobertura temporal. El conjunto disponible abarca del 1 de enero al 29 de agosto de 2025. No permite describir 2022-2024, el último cuatrimestre de 2025 ni inferir un patrón anual completo.

Resolución temporal. El archivo contiene fecha de alerta y turno, pero no hora individual de ocurrencia; por ello no se analizarán patrones horarios y la fecha de alerta puede no coincidir exactamente con la del hecho.

Registro de lo atendido, no de lo ocurrido. La capa SIPCOP Municipal documenta ocurrencias registradas por el patrullaje municipal e integrado (el 51 % de los registros proviene de Patrullaje Local Integrado), que incluyen hechos de seguridad que no son nece-

sariamente delitos (el 34 % corresponde a exposición a peligro o abandono de personas); no incluye los hechos no reportados ni los denunciados solo ante la Policía Nacional. Los patrones describen lo registrado en la capa y no la totalidad del delito ni necesariamente todos los servicios atendidos.

Precisión de la ubicación. La exactitud de las coordenadas depende del modo de registro y condiciona la elección del radio ε.

Sensibilidad a los parámetros. Los grupos obtenidos con DBSCAN dependen de ε y MinPts; se documentará un análisis de sensibilidad.

Alcance inferencial. El diseño es observacional: los resultados describen patrones y no establecen causas ni son generalizables a otros distritos. El registro refleja también dónde y cuándo se patrulla: el 76 % de los registros nace del patrullaje y solo 232 proceden de llamadas ciudadanas, alarmas o mensajería, lo que puede inflar la presencia de ocurrencias en zonas y turnos con mayor cobertura. Este sesgo se mide con un análisis de sensibilidad por origen del registro.

CAPÍTULO II

MARCO TEÓRICO Y ESTADO DEL ARTE

2.1. Antecedentes y estado del arte

La revisión que sigue es preliminar: agrupa los estudios por su alcance y establece la brecha que justifica el plan. Deberá actualizarse con una búsqueda sistemática antes de la sustentación.

2.1.1. Antecedentes internacionales

Sherman et al. (1989) analizaron las llamadas a la policía en Minneapolis y mostraron que una fracción reducida de las direcciones concentraba una parte desproporcionada de los incidentes, lo que dio sustento empírico a la noción de *hot spot*. Weisburd (2015) generalizó este resultado como la "ley de la concentración del delito": en distintas ciudades, un porcentaje pequeño de microlugares reúne cerca de la mitad de los hechos y esa concentración es estable en el tiempo. Ambos trabajos justifican analizar el delito por lugares y no solo por unidades administrativas amplias.

En cuanto a los métodos, Chainey et al. (2008) compararon técnicas de mapeo de *hotspots* según su capacidad de anticipar la localización de delitos futuros y encontraron que la densidad kernel tuvo un desempeño predictivo competitivo frente a otras técnicas. Hu et al. (2018) propusieron un marco de densidad kernel espacio-temporal para la elaboración de mapas predictivos de *hotspots* y su evaluación, lo que muestra la utilidad de incorporar el tiempo junto con el espacio. Estos estudios sustentan el uso de la densidad kernel como visualización complementaria, pero no resuelven cómo delimitar grupos discretos de ocurrencias.

2.1.2. Antecedentes nacionales

Cutid-Aguero et al. (2025) analizaron el delito en la Provincia Constitucional del

Callao (febrero de 2024) con minería de datos espaciales: emplearon densidad kernel para visualizar *hotspots* y DBSCAN, con ε seleccionado mediante el gráfico de *k*-distancias, para detectar grupos discretos. Reportan una fuerte concentración geográfica de los incidentes y un grupo de 317 ocurrencias en el Cercado del Callao, y concluyen que el delito sigue patrones geográficos definidos. Es el antecedente más cercano a este plan por la técnica y por el contexto peruano.

Mamani Ramos (2019) desarrolló un sistema de geo-sectorización de zonas delictivas con el algoritmo K-Means y visualización en mapas, aplicado al contexto turístico y con datos abiertos de Buenos Aires. K-Means exige fijar el número de grupos de antemano y asigna todos los puntos a un grupo, a diferencia de DBSCAN, que admite ruido y formas arbitrarias.

2.1.3. Antecedentes locales

En la búsqueda preliminar no se identificaron estudios publicados que apliquen técnicas de agrupamiento espacial a registros de serenazgo del distrito de San Sebastián o de la ciudad del Cusco. Esta afirmación es provisional y se confirmará con una búsqueda en los repositorios institucionales (UNSAAC, ALICIA y RENATI).

2.1.4. Síntesis y brecha de investigación

La Tabla 1 resume los antecedentes. La literatura establece la concentración espacial del delito y dispone de técnicas para detectarla; en el Perú existe al menos un antecedente reciente con DBSCAN. Sin embargo, no se dispone de un análisis documentado de las ocurrencias del patrullaje municipal de San Sebastián que combine agrupamiento espacial con el contraste estadístico de su recurrencia temporal y que informe la calidad del agrupamiento y la sensibilidad a los parámetros. Esa es la brecha que este plan se propone abordar, sin presuponer que los patrones existan.

Tabla 1. *Síntesis de los antecedentes revisados.*

Estudio	Técnica	Aporte	Limitación respecto de este plan
Sherman et al. (1989)	Conteo por dirección	Concentración del delito en pocos lugares	No usa agrupamiento algorítmico
Weisburd (2015)	Concentración en microlugares	Regularidad de la concentración y estabilidad temporal	Otro contexto y escala
Chainey et al. (2008)	Comparación de mapeo de *hotspots*	Desempeño predictivo de la densidad kernel	No delimita grupos discretos
Hu et al. (2018)	Densidad kernel espacio-temporal	Mapas predictivos y su evaluación	Otro contexto; fines predictivos
Cutid-Aguero et al. (2025)	Densidad kernel y DBSCAN	Aplicación en el Callao, ε por k-distancias	Otra jurisdicción; un solo mes
Mamani Ramos (2019)	K-Means	Geo-sectorización con datos de Buenos Aires	Número de grupos fijo; sin ruido

Nota. Elaboración propia.

2.2. Fundamentos teóricos

2.2.1. Seguridad ciudadana y concentración del delito

La seguridad ciudadana designa la protección de las personas frente a hechos que amenazan su integridad y sus bienes, y en el Perú se organiza como un sistema con participación de los gobiernos locales (Congreso de la República del Perú, 2003). El serenazgo es el servicio municipal que realiza patrullaje y prevención en el distrito. La teoría de las actividades rutinarias sostiene que el delito se produce cuando coinciden en el espacio y el tiempo un ofensor motivado, un objetivo adecuado y la ausencia de guardianes (Cohen and Felson, 1979); de ello se sigue que los incidentes tiendan a agruparse en ciertos lugares y horarios, y que esa regularidad pueda estudiarse mediante mapas y estadística (Eck et al., 2005; Weisburd, 2015).

2.2.2. Análisis espacial

El análisis espacial estudia la distribución geográfica de los eventos, su densidad y su agrupamiento (Chainey and Ratcliffe, 2005). Una vez confirmado que las coordenadas del archivo pueden transformarse a coordenadas geográficas WGS84, la distancia entre dos

ocurrencias se calculará con la fórmula haversine (Sinnott, 1984):

$$d(p,q) = 2R \arcsin \sqrt{\sin^2\left(\frac{\varphi_q - \varphi_p}{2}\right) + \cos\varphi_p \cos\varphi_q \sin^2\left(\frac{\lambda_q - \lambda_p}{2}\right)} \tag{1}$$

donde R es el radio medio de la Tierra, φ la latitud y λ la longitud, ambas en radianes.

La densidad de eventos en una ubicación x puede estimarse mediante densidad kernel (Silverman, 1986):

$$\hat{f}(x) = \frac{1}{nh^2} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right) \tag{2}$$

donde n es el número de ocurrencias, h el ancho de banda y $K(\cdot)$ la función kernel. La densidad kernel produce una superficie continua apta para mapas de calor, pero no delimita grupos de ocurrencias; en este estudio se usa solo como visualización.

2.2.3. Agrupamiento espacial por densidad

DBSCAN (Ester et al., 1996) agrupa los puntos según su densidad a partir de la vecindad de cada uno:

$$N_\varepsilon(p) = \{\, q \in D \mid d(p,q) \leq \varepsilon \,\} \tag{3}$$

Un punto es *núcleo* si $|N_\varepsilon(p)| \geq \text{MinPts}$; los puntos alcanzables desde un núcleo forman un grupo, y los restantes se etiquetan como ruido. El método no requiere fijar el número de grupos, admite formas arbitrarias y es sensible a ε y MinPts (Schubert et al., 2017). Una guía habitual para elegir ε es el gráfico de k-distancias, donde se busca el "codo" de la curva ordenada de distancias al k-ésimo vecino. HDBSCAN (Campello et al., 2013; McInnes et al., 2017) extiende la idea a una jerarquía de densidades y no requiere fijar ε, aunque sí un tamaño mínimo de grupo.

2.2.4. Resolución y error de georreferenciación

Las coordenadas de los registros policiales suelen proceder de la geocodificación de direcciones o de puntos de referencia, y su error posicional afecta la detección de concentraciones; por eso se recomienda informar la proporción de registros georreferenciados y la precisión lograda (Ratcliffe, 2004). Cuando las coordenadas están redondeadas a una malla,

varios registros comparten la misma ubicación y las distancias menores que el paso de la malla no son observables. En consecuencia, el radio ε de DBSCAN no debe ser menor que ese paso, los puntos coincidentes se cuentan como registros distintos al evaluar MinPts y la simulación del modelo nulo debe reproducir la misma cuantización.

2.2.5. Inferencia sobre concentraciones espaciales y espacio-temporales

Un grupo devuelto por un algoritmo no demuestra por sí solo una concentración mayor que la esperable por azar. Para contrastarla se dispone de simulaciones Monte Carlo del tamaño de los grupos bajo un modelo nulo, de la función K de Ripley (Ripley, 1976), que describe el agrupamiento a distintas escalas, y del estadístico de escaneo espacial de Kulldorff (Kulldorff, 1997), que busca ventanas con exceso de casos frente a una población de referencia. La interacción entre espacio y tiempo puede evaluarse con la prueba de Knox (Knox, 1964). En este plan el contraste principal es la simulación Monte Carlo de la sección 3.6.3; la función K y el escaneo de Kulldorff se consideran contrastes complementarios.

2.2.6. Evaluación de la calidad del agrupamiento

El coeficiente de silueta (Rousseeuw, 1987) compara, para cada punto i, la distancia media a los puntos de su grupo, $a(i)$, con la distancia media al grupo vecino más cercano, $b(i)$:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \qquad -1 \leq s(i) \leq 1 \tag{4}$$

Valores cercanos a 1 indican grupos compactos y bien separados. Como DBSCAN deja puntos sin grupo, la silueta se calcula sobre los puntos asignados y se informa junto con el porcentaje de ruido y el número de grupos.

2.2.7. Análisis temporal y pruebas estadísticas

Para contrastar si la frecuencia de ocurrencias por categoría temporal (turno, día de la semana, mes) difiere de la esperada se utiliza la prueba chi-cuadrado de Pearson (Pearson, 1900):

$$\chi^2 = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i} \tag{5}$$

donde O_i y E_i son las frecuencias observada y esperada de la categoría i. La prueba es fiable cuando las frecuencias esperadas no son demasiado pequeñas (Cochran, 1954). Su magnitud depende del tamaño de muestra, por lo que se complementa con el coeficiente V de Cramér (Cramér, 1946) como medida del tamaño del efecto.

2.2.8. Visualización geoespacial

Los mapas de calor, los mapas de puntos con grupos y los tableros permiten comunicar la distribución espacial y temporal de los incidentes a quienes toman decisiones operativas (Chainey and Ratcliffe, 2005). En este estudio se emplearán para presentar los *hotspots* identificados y para facilitar su interpretación por el personal de la municipalidad.

2.3. Definición de términos básicos

Ocurrencia de seguridad ciudadana: hecho atendido y registrado por el patrullaje municipal e integrado (serenazgo y Patrullaje Local Integrado), con fecha, turno, tipo y ubicación; no todos son delitos.

Grupo espacial (clúster): conjunto de ocurrencias agrupadas por un algoritmo según su densidad.

Hotspot: grupo espacial cuya concentración de ocurrencias supera la esperada por azar según un contraste estadístico.

Georreferenciación: asignación de coordenadas a un registro para ubicarlo en un sistema de referencia espacial.

Ruido: punto que DBSCAN no asigna a ningún grupo por hallarse en una zona de baja densidad.

Turno: franja horaria de operación del serenazgo (mañana, tarde y noche).

Aleatoriedad espacial completa (CSR): modelo en el que los puntos se distribuyen de forma independiente y uniforme en el área de estudio; sirve de referencia nula mínima; no incorpora población, vías ni patrullaje.

CAPÍTULO III

METODOLOGÍA DE LA INVESTIGACIÓN

3.1. Enfoque, tipo y diseño de investigación

3.1.1. Enfoque de investigación

La investigación tiene un enfoque cuantitativo: analiza datos numéricos de ocurrencias (coordenadas, fecha, turno) mediante procedimientos computacionales y pruebas estadísticas (Hernández-Sampieri and Mendoza, 2018).

3.1.2. Tipo y alcance de la investigación

Es de tipo aplicado, porque busca información útil para la gestión del serenazgo, y de alcance descriptivo e inferencial: describe la distribución espacial y temporal de las ocurrencias y contrasta si esa distribución difiere de la esperada por azar. No busca explicar causas.

3.1.3. Diseño de investigación

El diseño es no experimental y retrospectivo, con observaciones fechadas entre el 1 de enero y el 29 de agosto de 2025. No se manipula ninguna variable. El proceso de trabajo se alinea con las fases de CRISP-DM (Chapman et al., 2000): comprensión de los datos, preparación, modelado, evaluación y comunicación de resultados (Figura 1).

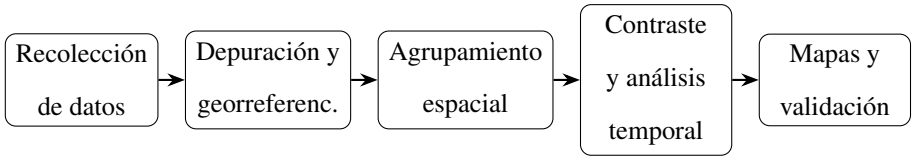


Figura 1. *Etapas del procedimiento metodológico.*

Nota. Elaboración propia, a partir de las fases de CRISP-DM (Chapman et al., 2000).

3.2. Definiciones y variables

3.2.1. Definiciones operativas

Ocurrencia de seguridad ciudadana: hecho atendido y registrado por el patrullaje municipal e integrado (serenazgo y Patrullaje Local Integrado) en el SIPCOP-M. Incluye hechos de distinta naturaleza; no todos son delitos: el 34 % de los registros es "exposición a peligro o abandono de personas", que probablemente corresponde a asistencia. Se definen dos conjuntos de análisis: el **principal**, con todo el extracto depurado, y el de **presuntos delitos**, que excluye esa modalidad y conserva las ocurrencias presuntamente contra el patrimonio y contra la vida, el cuerpo y la salud (unos 430 de 996 registros). La clasificación de cada modalidad se confirmará con la municipalidad.

Grupo espacial (clúster): conjunto de ocurrencias que DBSCAN o HDBSCAN agrupan por densidad. Es un resultado del algoritmo y, por sí solo, no implica que la concentración sea significativa.

Hotspot: grupo espacial cuyo número de ocurrencias supera lo esperado bajo aleatoriedad espacial completa, según el contraste de la sección 3.6.3.

3.2.2. Variables y operacionalización

Se trata de un estudio observacional sin variable independiente ni dependiente en sentido experimental. Se miden cuatro grupos de resultados, uno por cada propósito del estudio (Tabla 2).

Tabla 2. *Operacionalización de los resultados medidos.*

Objetivo	Dimensión	Indicadores	Instrumento
OE1	Calidad de los registros	Porcentaje de registros utilizables; duplicados; datos incompletos o fuera del distrito	Base del SIPCOP-M; registro de depuración
OE2	Concentración espacial	Número y tamaño de los grupos; porcentaje de ruido; valor p por grupo (Monte Carlo); silueta	DBSCAN; simulación en el polígono del distrito
OE2	Comparación de algoritmos	Índice de Rand ajustado entre asignaciones; número de grupos y ruido; estabilidad ante cambios de parámetros	DBSCAN y HDBSCAN
OE3	Comportamiento temporal	Frecuencias por turno, día de la semana y mes; χ^2, valor p ajustado y V de Cramér	Base del SIPCOP-M; pruebas estadísticas

Nota. Elaboración propia.

3.3. Unidad de análisis, población y muestra

3.3.1. Unidad de análisis

La unidad de análisis es la ocurrencia de seguridad ciudadana registrada en el SIPCOP-M, con su fecha, turno, tipo y ubicación. Los registros no tienen identificador único.

3.3.2. Población y muestra

La población accesible para este estudio está constituida por los 996 registros del extracto descargado de la capa SIPCOP Municipal, todos con `id_dist=080105` y fecha de alerta entre el 1 de enero y el 29 de agosto de 2025. Se realizará un censo de ese extracto, no una muestra probabilística. Este total describe el archivo disponible y no se interpreta como la totalidad de las ocurrencias realmente atendidas por el serenazgo.

Criterios de inclusión: registros dentro del periodo, con fecha, turno, categoría y coordenadas utilizables, y cuya ubicación corresponda al distrito tras validar el sistema de referencia. **Criterios de exclusión:** duplicados exactos (filas idénticas en los 19 campos; son 10, con lo que 996 pasa a 986), registros sin campos esenciales o con coordenadas fuera del distrito. Como el archivo carece de identificador, los 70 registros con igual fecha, turno

y coordenadas ("casi duplicados") no se eliminan, porque pueden ser hechos distintos en puntos recurrentes; se evalúa su efecto en el análisis de sensibilidad. El número de registros excluidos por cada criterio se informará (Anexo 3).

3.3.3. Diagnóstico preliminar del extracto

Antes del análisis se revisó el archivo descargado (Tabla 3). Este diagnóstico no contrasta ninguna hipótesis; sirve para fijar los parámetros del diseño con criterios explícitos.

Tabla 3. *Diagnóstico preliminar del extracto SIPCOP Municipal de San Sebastián.*

Aspecto	**Hallazgo**
Registros y periodo	996 filas, 19 columnas; 1/1–29/8/2025 (241 días, 215 con registro y 26 sin ningún registro)
Resolución espacial	Coordenadas en grados decimales con 3 decimales (unos 108 m en x y 111 m en y); 412 ubicaciones distintas; 765 registros (77 %) comparten coordenada exacta con otro
Duplicados	10 filas idénticas; 70 con igual fecha, turno y coordenadas; sin identificador único
Volumen mensual	Registros por día: 4,9 (ene.), 5,0 (feb.), 3,1 (mar.), 4,2 (abr.), 3,1 (may.), 2,0 (jun.), 3,5 (jul.) y 7,5 (ago., hasta el 29)
Cambio de clasificación	Exposición a peligro o abandono: 339 registros (34 %); 57 % de los registros de enero y 9–17 % de junio a agosto
Origen del registro	Patrullaje 760 (76 %); teléfono 216, alarma 13, mensajería 3; cámara, operativo y otros 4
Personal	Patrullaje Local Integrado 504 (51 %); Patrullaje Municipal – Serenazgo 492
Campos esenciales	`fechaalerta`, `turno`, `especifico`, `modalidad`, `x` e `y` sin valores nulos
Campos incompletos	`lugarocurrencia` 22 % faltante; `resultadoocurrencia` 67 % (casi solo en hechos contra la vida, el cuerpo y la salud); `consecuencia` 10 %; `medioutilizado` 32 % faltante y 64 % "OTROS"
Campos constantes	`generico`, `estado` e `id_dist`

Nota. Elaboración propia a partir del CSV SIPCOP Municipal (separador `;`, UTF-8 con BOM, fechas en texto en español, por ejemplo "agosto 23, 2025").

La Figura 2 muestra las 412 ubicaciones distintas: se concentran en dos franjas este–oeste y varias repiten la misma coordenada, lo que es coherente con una geocodificación por puntos de referencia. La Figura 3 muestra que el volumen de registro y la proporción de

la modalidad de exposición a peligro o abandono cambian entre meses. Ambas figuras son descriptivas y orientan la elección del radio ε y de la referencia temporal; no constituyen evidencia de concentración ni de patrón temporal alguno.

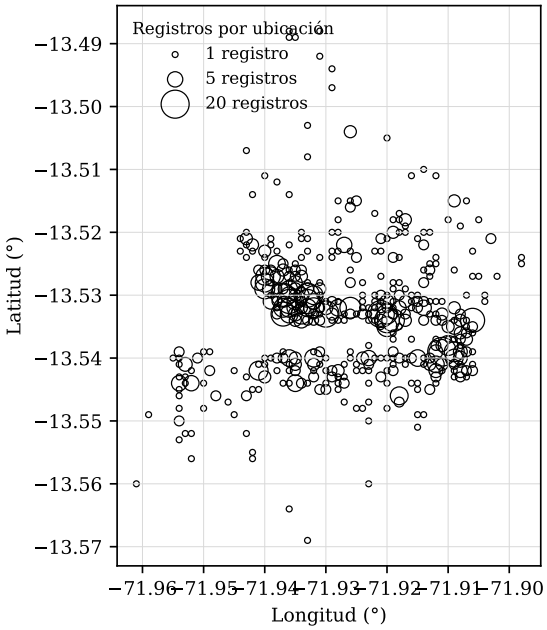


Figura 2. *Ubicaciones distintas del extracto SIPCOP Municipal (San Sebastián, 2025).*

Nota. Elaboración propia a partir del CSV SIPCOP Municipal. El tamaño del círculo es proporcional al número de registros con esa coordenada; $n = 996$ registros en 412 ubicaciones. Generada con `datos/figuras_diagnostico.py`.

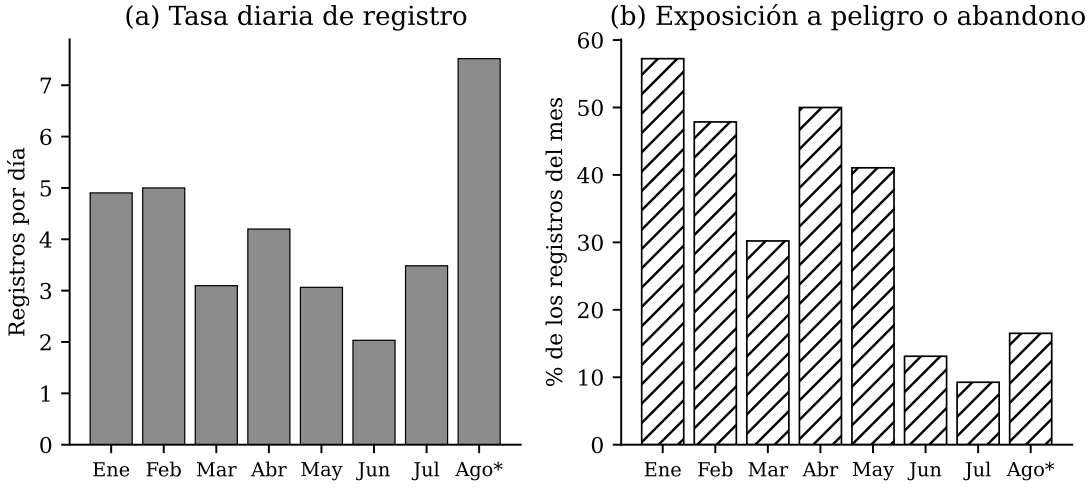


Figura 3. *Volumen de registro y modalidad de exposición a peligro o abandono por mes.*

Nota. Elaboración propia a partir del CSV SIPCOP Municipal. (*) Agosto incluye solo hasta el 29. En (a), la tasa es el número de registros dividido entre los días del mes observados; en (b), el porcentaje se calcula sobre los registros de cada mes.

3.4. Técnicas e instrumentos de recolección

- **Análisis documental:** revisión del archivo CSV público de la capa SIPCOP Municipal para el distrito `080105`; se conservarán la URL de origen, fecha de descarga y archivo original para trazabilidad. Se solicitará a la municipalidad o al responsable de la capa la definición de los campos y del sistema de referencia espacial.
- **Instrumento:** ficha de estructura de datos (Anexo 2), que documenta las 19 columnas del archivo. Los campos analíticos son `fechaalerta`, `turno`, `especifico`, `modalidad`, `x` e `y`; se usan además `origen`, `naturalezadelpersonal`, `lugarocurrencia`, `consecuencia`, `formapatrullaje`, `direccion` y `tipovia` para la calidad de datos y los análisis de sensibilidad. El archivo no contiene una hora individual del hecho.
- **Cartografía:** polígono oficial del distrito y, si está disponible, la capa de manzanas o vías, para delimitar el área de simulación.
- **Herramientas de análisis:** Python con las bibliotecas *pandas*, *scikit-learn* (Pedregosa et al., 2011), *hdbscan* (McInnes et al., 2017) y *SciPy*; un sistema de información geográfica para los mapas.

3.5. Procedimiento metodológico

1. **Obtención y documentación.** Preservación del CSV disponible (996 registros; `id_dist=080105`) y registro de su procedencia. Se consultará el significado de `fechaalerta`, los horarios de turno, las definiciones de categoría y la confirmación del sistema de referencia (el diagnóstico indica longitud y latitud en grados decimales, WGS84); cualquier autorización o validación municipal necesaria se gestionará antes de difundir resultados.
2. **Depuración.** Revisión de duplicados, parseo de fechas, normalización de turnos y categorías, y comprobación de que las coordenadas correspondan al distrito. Se calculará la proporción de registros utilizables (objetivo específico 1) y se documentarán exclusiones.

3. **Validación espacial.** Se verificará que `x` sea longitud e `y` latitud y que el sistema de referencia sea WGS84. Además se revisarán tres aspectos: (i) la cuantización a 0,001° y los ceros finales omitidos (126 valores de `x` y 145 de `y` tienen solo dos decimales); (ii) el contraste entre `direccion` y las coordenadas, usando puntos de referencia reconocibles (paraderos, el cementerio, el centro de salud); y (iii) la superposición con el polígono oficial del distrito. Solo después se transformarán a un sistema proyectado métrico o se usará haversine; si no se logra confirmar la referencia, no se interpretarán distancias ni agrupamientos métricos.
4. **Análisis exploratorio.** Series por mes, día de la semana y turno dentro del periodo disponible; mapa de puntos y de densidad kernel (solo como visualización).
5. **Agrupamiento espacial.** Se aplica DBSCAN con distancia haversine (Algoritmo 1) y se elige la configuración según la regla de la sección 3.6.1. HDBSCAN se ejecuta como comparación.
6. **Contraste de la concentración espacial.** Prueba Monte Carlo por grupo frente a aleatoriedad espacial completa (sección 3.6.3); los grupos significativos son los *hotspots*.
7. **Análisis temporal de los *hotspots*.** Contrastes chi-cuadrado por turno, día de la semana y mes (sección 3.6.4).
8. **Validación y presentación.** Revisión de los *hotspots* con el personal del patrullaje municipal y elaboración de mapas.

Algoritmo 1. DBSCAN aplicado a las ocurrencias georreferenciadas.

1. Inicializar $C \leftarrow 0$ y marcar todos los puntos como no visitados.
2. Para cada punto $p \in D$ no visitado: marcarlo como visitado y calcular su vecindario $N_\varepsilon(p)$ con la distancia d (ecuación 1).
3. Si $|N_\varepsilon(p)| <$ MinPts, etiquetar p como ruido.
4. En caso contrario, crear un nuevo grupo C, asignar p a dicho grupo y expandirlo con todos los puntos alcanzables dentro del radio ε.
5. Repetir hasta que todos los puntos queden etiquetados como pertenecientes a un grupo o como ruido.

3.6. Protocolo de evaluación

3.6.1. Selección de parámetros y calidad del agrupamiento

La regla de selección se fija antes de ver los resultados de los contrastes. Las coordenadas tienen resolución de 0,001° (unos 108–111 m): dos puntos de celdas distintas distan al menos ese paso, de modo que con $\varepsilon \leq 100$ m solo se agrupan registros con coordenada idéntica, y $\varepsilon = 50$ y 100 m producen la misma partición (diagnóstico preliminar). Por ello se explora una rejilla de $\varepsilon \in \{150, 200, 250, 300\}$ m y MinPts $\in \{10, 20, 30\}$, y el gráfico de *k*-distancias orienta el rango de ε. Los registros con coordenadas idénticas cuentan como puntos separados al evaluar MinPts. Para cada configuración se calculan el número de grupos, el porcentaje de ruido y la silueta media (ecuación 4) sobre los puntos asignados. Se elige la configuración con mayor estabilidad, medida como el índice de Rand ajustado promedio (ARI) (Hubert and Arabie, 1985) entre sus asignaciones y las de las configuraciones vecinas de la rejilla, entre las que tengan al menos dos grupos, menos de 60 % de ruido y ningún grupo que reúna más de 25 % de los registros depurados o supere 1 km de diámetro, para que no domine un grupo único formado por encadenamiento. La silueta no decide la elección y se interpreta con cautela, porque los puntos coincidentes (distancia cero) y la malla de coordenadas la distorsionan. Se presentará además el análisis de sensibilidad con las demás configuraciones.

3.6.2. Comparación entre DBSCAN y HDBSCAN

Se compararán las asignaciones de ambos algoritmos mediante el ARI, el número de grupos, el porcentaje de ruido y la coincidencia de los grupos grandes (los centroides a menos de ε de distancia). Para HDBSCAN se variará el tamaño mínimo de grupo en un rango análogo a MinPts. La comparación es descriptiva: no se declara un algoritmo “correcto”, sino en qué zonas coinciden y en cuáles difieren.

3.6.3. Concentración espacial frente al azar

El modelo nulo de referencia es la aleatoriedad espacial completa (CSR): n puntos independientes y uniformes dentro del **polígono real del distrito**, con el mismo n que los datos depurados. La CSR es la referencia mínima, no un contraste exigente: casi cualquier ciudad rechaza la uniformidad porque la población, las vías y el comercio no se reparten de manera uniforme. Por eso se añade un **segundo modelo nulo**: la simulación restringida al área urbanizada (manzanas o vías) y, para los análisis por tipo de ocurrencia, la simulación con intensidad proporcional a la densidad kernel de todas las ocurrencias del extracto (de modo que se pregunte si un tipo se concentra más que el conjunto). Se informan los resultados bajo ambos nulos.

Se simulan $B = 999$ conjuntos y a cada uno se le aplica el agrupamiento con los parámetros ya elegidos para los datos reales, tras redondear las coordenadas simuladas a la misma rejilla de 0,001°; de lo contrario los datos reales parecerían más densos que el azar solo por la cuantización. El estadístico es el tamaño m_j de cada grupo observado j. Su valor p se calcula contra el tamaño del mayor grupo de cada simulación, M_b, lo que controla el error en las comparaciones entre grupos:

$$p_j = \frac{1 + \#\{\, b : M_b \geq m_j \,\}}{1 + B} \tag{6}$$

Un grupo con $p_j < \alpha$ se considera un *hotspot*. La comparación global (número de puntos en grupos frente a lo simulado) se informa como apoyo para H_1. Esta prueba se limita a comparar con una distribución uniforme: no distingue entre concentración por mayor actividad delictiva y concentración por mayor población, vías o presencia de patrullaje.

3.6.4. Distribución temporal de los *hotspots*

Para cada *hotspot* se compara la distribución de sus ocurrencias según fecha de alerta (día de la semana y mes) y turno con la del resto del distrito, es decir, con las ocurrencias que no pertenecen a ese *hotspot*. La referencia principal es la prueba chi-cuadrado de homogeneidad (ecuación 5) sobre la tabla de contingencia *hotspot* frente a resto por categoría

temporal; cuando más del 20 % de las frecuencias esperadas sea menor que 5 se usa una prueba de permutación (Cochran, 1954). Esta referencia absorbe la variación del volumen de registro entre meses, que es grande en el extracto (de 2,0 registros diarios en junio a 7,5 en agosto) y que no se debe a ningún *hotspot* en particular.

Como **análisis secundario** se contrasta, mediante chi-cuadrado de bondad de ajuste, si cada *hotspot* sigue la distribución esperada por exposición calendario:

- **Turno:** proporcional a las horas de cada turno según la organización real del patrullaje (se pedirá a la municipalidad).
- **Día de la semana:** proporcional al número de veces que ocurre cada día calendario entre el 1 de enero y el 29 de agosto de 2025.
- **Mes:** proporcional al número de días observados de cada mes, incluidos enero y agosto parciales.

Como la tasa mensual de registro cambia tanto, esta referencia se rechazará casi con seguridad aun sin concentración espacial alguna; se informa pero no sustenta por sí sola H_2. Además, 26 de los 241 días no tienen registro y se desconoce si hubo cero eventos o falta de reporte; los contrastes se repiten sobre días con registro y sobre todos los días. El cambio de clasificación de "exposición a peligro o abandono" entre meses se controla repitiendo los contrastes sin esa modalidad (sección 3.6.5).

Los contrastes suponen un riesgo constante en el tiempo y no prueban causalidad. Para evaluar si los *hotspots* difieren entre sí en su distribución temporal se usa además la prueba chi-cuadrado de independencia sobre la tabla *hotspot* por categoría temporal, con el tamaño del efecto medido mediante el coeficiente V de Cramér:

$$V = \sqrt{\frac{\chi^2}{n \min(r-1, c-1)}} \tag{7}$$

donde n es el total de ocurrencias y r y c el número de filas y de columnas de la tabla de contingencia.

3.6.5. Análisis de sensibilidad

Los resultados principales se repiten en cuatro variantes para valorar su robustez: (i) solo registros de origen ciudadano o de alarma (teléfono, alarma y mensajería; 232 registros), que dependen menos de dónde patrulla el personal; se declara de antemano que, por ser pocos registros, solo admitirán valores bajos de MinPts; (ii) el conjunto de presuntos delitos, sin la modalidad de exposición a peligro o abandono, por su cambio de clasificación entre meses; (iii) sin los 70 casi duplicados (misma fecha, turno y coordenadas); y (iv) con un desplazamiento aleatorio uniforme de ± 55 m en las coordenadas, que aproxima el error por redondeo. Una conclusión se considera robusta solo si se mantiene en la mayoría de las variantes.

3.7. Métodos de análisis de datos

Se emplea estadística descriptiva (frecuencias, porcentajes, medidas de tendencia central) y las pruebas descritas arriba, con $\alpha = 0{,}05$. Como se contrastarán varios *hotspots* y tres variables temporales, los valores p de los contrastes temporales se ajustarán por comparaciones múltiples (corrección de Holm). Se fijará la semilla aleatoria y se versionarán los *scripts* para garantizar la reproducibilidad.

3.8. Aspectos éticos y de gestión de datos

El estudio utiliza registros administrativos disponibles públicamente y se ajustará a la Ley de Protección de Datos Personales (Congreso de la República del Perú, 2011) y a las condiciones de uso de la fuente. Se emplearán solo los campos necesarios (`fechaalerta`, `turno`, `especifico` o `modalidad`, coordenadas), sin nombres ni documentos personales. Antes de publicar resultados se confirmarán las condiciones de reutilización con la entidad responsable; los resultados se agregarán por grupo y los mapas evitarán identificar domicilios concretos. El archivo de trabajo se almacenará de forma segura y se utilizará únicamente con fines de investigación.

CAPÍTULO IV

ESTUDIO DE FACTIBILIDAD

4.1. Enfoque adoptado

El proyecto se apoya en datos que la municipalidad ya produce y en herramientas de código abierto, sin entrenar modelos complejos ni requerir equipamiento especializado. La factibilidad se analiza en sus dimensiones técnica, económica y operativa.

4.2. Factibilidad técnica

4.2.1. Hardware y cómputo

El volumen disponible (996 registros de un distrito para enero-agosto de 2025) es manejable en un computador personal de gama media. DBSCAN y la simulación Monte Carlo (999 repeticiones) son ejecutables en ese equipo en tiempos razonables.

4.2.2. Datos

El CSV SIPCOP Municipal ya está disponible y se realizó un diagnóstico preliminar (Tabla 3): los 996 registros no tienen valores nulos en fecha, turno, tipo ni coordenadas, las coordenadas están en grados decimales con resolución de unos 110 m (412 ubicaciones distintas) y el volumen de registro varía de 2,0 a 7,5 por día entre meses. Los riesgos principales son la interpretación de `fechaalerta`, la ausencia de un diccionario que defina el sistema de referencia de `x` e `y`, la definición de las categorías y el cambio de clasificación entre meses. Se mitigarán documentando la fuente, consultando a la entidad responsable en las primeras semanas (de lo que dependen la rejilla de ε y la referencia temporal) y tratando la evaluación de calidad como primer resultado (objetivo específico 1). Si no se confirma la referencia espacial, se limitará el análisis a los resultados que no dependan de distancias.

4.2.3. Herramientas y software

Se emplearán Python y sus bibliotecas de ciencia de datos (*pandas*, *scikit-learn*, *hdbscan*, *SciPy*), un sistema de información geográfica de código abierto para los mapas y LaTeX para la redacción. Todas son de uso libre.

4.3. Factibilidad económica

El presupuesto estimado (Tabla 5) asciende a S/ 1 220,00, compuesto por gastos de servicios, materiales y trámites; al no requerir hardware ni licencias adicionales, es asumible con recursos propios.

4.4. Factibilidad operativa

El extracto público permite iniciar el análisis sin esperar una nueva entrega de datos. Se procurará la colaboración de la Municipalidad Distrital de San Sebastián para validar las definiciones de los campos, los horarios de turno y, de ser posible, interpretar los *hotspots*; también se verificarán las condiciones de reutilización y difusión. El estudio no implica intervención sobre personas ni trabajo de campo extenso.

4.5. Viabilidad y sostenibilidad

El procedimiento (depuración, agrupamiento, contraste temporal) es replicable sobre nuevos periodos de datos y en otros distritos, y el uso de herramientas libres favorece que la municipalidad lo mantenga. La principal condición de continuidad es que el registro conserve coordenadas válidas.

CAPÍTULO V

ASPECTOS ADMINISTRATIVOS

5.1. Cronograma de actividades

El proyecto se ejecuta en 16 semanas, entre el 19 de octubre de 2026 y el 7 de febrero de 2027. La Tabla 4 presenta el diagrama de Gantt.

Tabla 4. *Cronograma de actividades por semanas (octubre 2026 – febrero 2027).*

	Oct				Nov				Dic				Ene			Feb
Actividad	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
Aprobación del plan de tesis	■	■														
Solicitud de autorización y acceso a datos	■	■	■	■												
Reunión con la municipalidad (CRS, fecha de alerta, turnos, categorías)	■	■														
Revisión del estado del arte	■	■	■	■												
Depuración y georreferenciación			■	■	■											
Control de calidad y ajuste del diseño (rejilla de ε, referencia temporal)					■	■										
Análisis exploratorio						■	■									
Agrupamiento espacial (DBSCAN/HDBSCAN)							■	■	■							
Prueba Monte Carlo y contrastes temporales								■	■	■	■					
Mapas y validación con el patrullaje municipal										■	■	■				
Redacción del informe final											■	■	■	■	■	
Sustentación															■	■

Nota. Elaboración propia. Cada columna es una semana; la semana 1 inicia el 19 de octubre de 2026.

5.2. Presupuesto y financiamiento

La Tabla 5 resume los recursos estimados, que serán financiados con recursos propios del tesista.

Tabla 5. *Presupuesto estimado del proyecto (soles).*

Rubro	Descripción	Costo (S/)
Servicios	Acceso a Internet durante cuatro meses	240,00
Materiales	Papel, impresiones y anillado de ejemplares	300,00
Trámites	Inscripción, derechos y trámites administrativos de la tesis	400,00
Movilidad	Traslados a la Municipalidad Distrital y a reuniones con el asesor	180,00
Imprevistos	Gastos no previstos	100,00
Total		**1 220,00**

Nota. Elaboración propia. Los montos son estimaciones y se actualizarán con las tarifas vigentes.

5.3. Equipo de investigación

Tabla 6. *Equipo de investigación.*

Rol	Responsable y función
Tesista	Br. Ronaldo Ticona Jancco: diseño, ejecución del análisis y redacción.
Asesor	Por designar: orientación metodológica y técnica.
Colaboradores	Personal de la Municipalidad Distrital de San Sebastián (acceso a datos y validación de los *hotspots*).

Nota. Elaboración propia.

REFERENCIAS

Campello, R. J. G. B., Moulavi, D., y Sander, J. (2013). Density-based clustering based on hierarchical density estimates. En *Advances in Knowledge Discovery and Data Mining (PAKDD 2013)*, pp. 160–172. Springer.

Chainey, S. y Ratcliffe, J. (2005). *GIS and Crime Mapping*. Wiley.

Chainey, S., Tompson, L., y Uhlig, S. (2008). The utility of hotspot mapping for predicting spatial patterns of crime. *Security Journal*, 21(1–2):4–28.

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., y Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. Informe técnico, SPSS Inc.

Cochran, W. G. (1954). Some methods for strengthening the common χ^2 tests. *Biometrics*, 10(4):417–451.

Cohen, L. E. y Felson, M. (1979). Social change and crime rate trends: A routine activity approach. *American Sociological Review*, 44(4):588–608.

Congreso de la República del Perú (2003). Ley N.º 27933, Ley del Sistema Nacional de Seguridad Ciudadana.

Congreso de la República del Perú (2011). Ley N.º 29733, Ley de Protección de Datos Personales.

Cramér, H. (1946). *Mathematical Methods of Statistics*. Princeton University Press.

Cutid-Aguero, J., Alarcon-Ventura, K., Canales-Escalante, C., Huaman-Yrigoin, D., Zarate-Bocanegra, J.-A., Solis-Tipian, M., y Zevallos-Vera, E. (2025). Spatial-temporal analysis and characterization of crime in the Constitutional Province of Callao, February 2024: An approach based on spatial data mining. En *5th LACCEI International Multiconference on Entrepreneurship, Innovation and Regional Development (LEIRD 2025)*, Edición virtual.

Eck, J. E., Chainey, S., Cameron, J. G., Leitner, M., y Wilson, R. E. (2005). Mapping crime: Understanding hot spots. Informe técnico, National Institute of Justice.

Ester, M., Kriegel, H.-P., Sander, J., y Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. En *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD-96)*, pp. 226–231. AAAI Press.

Hernández-Sampieri, R. y Mendoza, C. P. (2018). *Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta*. McGraw-Hill.

Hu, Y., Wang, F., Guin, C., y Zhu, H. (2018). A spatio-temporal kernel density estimation framework for predictive crime hotspot mapping and evaluation. *Applied Geography*, 99:89–97.

Hubert, L. y Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2(1):193–218.

Instituto Nacional de Estadística e Informática (2023). Encuesta nacional de programas presupuestales (ENAPRES). Informe técnico, periodo noviembre 2022-abril 2023.

Knox, E. G. (1964). The detection of space-time interactions. *Journal of the Royal Statistical Society. Series C (Applied Statistics)*, 13(1):25–29.

Kulldorff, M. (1997). A spatial scan statistic. *Communications in Statistics – Theory and Methods*, 26(6):1481–1496.

Mamani Ramos, Y. L. (2019). Sistema de geo-sectorización de la inseguridad ciudadana para la sectorización de zonas delictivas en el contexto turístico utilizando algoritmos de clustering. Tesis de grado, Universidad Peruana Unión. Repositorio institucional UPeU. http://repositorio.upeu.edu.pe/handle/20.500.12840/2114.

McInnes, L., Healy, J., y Astels, S. (2017). hdbscan: Hierarchical density based clustering. *Journal of Open Source Software*, 2(11):205.

Pearson, K. (1900). On the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling. *Philosophical Magazine, Series 5*, 50(302):157–175.

Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Policía Nacional del Perú (2024). Denuncias por homicidio, departamento de cusco, 2022-2024. Estadística de denuncias, enero-noviembre de 2024.

Ratcliffe, J. H. (2004). Geocoding crime and a first estimate of a minimum acceptable hit rate. *International Journal of Geographical Information Science*, 18(1):61–72.

Ripley, B. D. (1976). The second-order analysis of stationary point processes. *Journal of Applied Probability*, 13(2):255–266.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20:53–65.

Schubert, E., Sander, J., Ester, M., Kriegel, H.-P., y Xu, X. (2017). DBSCAN revisited, revisited: Why and how you should (still) use DBSCAN. *ACM Transactions on Database Systems*, 42(3):19:1–19:21.

Sherman, L. W., Gartin, P. R., y Buerger, M. E. (1989). Hot spots of predatory crime: Routine activities and the criminology of place. *Criminology*, 27(1):27–56.

Silverman, B. W. (1986). *Density Estimation for Statistics and Data Analysis*. Chapman and Hall.

Sinnott, R. W. (1984). Virtues of the haversine. *Sky and Telescope*, 68(2):159.

Weisburd, D. (2015). The law of crime concentration and the criminology of place. *Criminology*, 53(2):133–157.

Anexo 1

Matriz de consistencia

Tabla 7. *Matriz de consistencia.*

Problema	**Objetivo**	**Hipótesis**	**Técnica**
General: ¿cuáles son los patrones de distribución espacial y temporal de las ocurrencias del extracto SIPCOP Municipal de San Sebastián, del 1/1 al 29/8 de 2025?	Analizar la distribución espacial y temporal del extracto mediante técnicas de agrupamiento y procedimientos estadísticos	H_G (sección 1.3)	Agrupamiento espacial y análisis temporal
PE1: proporción de ocurrencias utilizables, resolución espacial y convención de georreferenciación	OE1: evaluar la calidad y cobertura de los registros del SIPCOP-M y caracterizar la resolución de las coordenadas	Descriptivo (sin hipótesis)	Depuración, diagnóstico y georreferenciación
PE2: concentraciones espaciales, cuáles superan el azar y coincidencia con HDBSCAN	OE2: identificar y contrastar las concentraciones con DBSCAN y compararlas con HDBSCAN	H_1	DBSCAN (ε de 150 a 300 m), HDBSCAN, ARI y prueba Monte Carlo con dos modelos nulos (CSR y área urbanizada)
PE3: distribución temporal de los *hotspots* frente al resto del distrito (y, como análisis secundario, frente a la exposición calendario)	OE3: analizar la distribución temporal de los *hotspots*	H_2	Chi-cuadrado de homogeneidad o permutación, V de Cramér, Holm y análisis de sensibilidad

Nota. Elaboración propia.

Anexo 2

Ficha de estructura de datos del SIPCOP-M

Tabla 8. *Campos del archivo CSV SIPCOP Municipal (19 columnas).*

Campo del CSV	Tipo	Descripción observada	Uso previsto
`fechaalerta`	Texto (fecha)	Fecha de alerta en español (“agosto 23, 2025”); semántica por confirmar	Día de semana, mes; conversión a fecha
`turno`	Categórica	Mañana, tarde, noche	Análisis temporal
`especifico`	Categórica	8 categorías (vida, cuerpo y salud; patrimonio; etc.)	Descripción, conjuntos por tipo
`modalidad`	Categórica	Modalidad presunta (por ejemplo, exposición a peligro o abandono, robo a personas)	Conjunto de presuntos delitos
`generico`	Categórica	Valor único: alertas tempranas en apoyo a la PNP	Delimita el extracto
`origen`	Categórica	Patrullaje, teléfono, alarma, WhatsApp, cámara, operativo, otros	Sensibilidad por origen
`naturalezadelpersonal`	Categórica	Patrullaje Local Integrado o Patrullaje Municipal – Serenazgo	Descripción y terminología
`formapatrullaje`	Categórica	Motorizado, a pie, bicicleta, otros	Descripción
`lugarocurrencia`	Categórica	Vía pública, inmueble particular, otros; 22 % faltante	Calidad de datos
`resultadoocurrencia`	Categórica	Consumado o frustrado; 67 % faltante	Calidad de datos
`consecuencia`	Categórica	Ninguno, materiales, lesiones, etc.; 10 % faltante	Calidad de datos
`medioutilizado`	Categórica	32 % faltante y 64 % “OTROS”	Calidad de datos
`tipovia`	Categórica	Calle, avenida, pasaje, jirón; 175 “SIN DATO”	Descripción
`direccion`	Texto libre	Dirección o punto de referencia; 5 “SIN DATO”	Contraste con coordenadas
`estado`, `estadoocurrencia`	Categórica	`estado` constante (activo); casi todos cerrados	Verificación
`id_dist`	Código	080105 en todo el extracto	Verificación del ámbito
`x`	Numérica (texto)	Longitud en grados decimales, 3 decimales (unos 108 m)	Análisis espacial tras validar
`y`	Numérica (texto)	Latitud en grados decimales, 3 decimales (unos 111 m)	Análisis espacial tras validar

Nota. Campos observados en el CSV disponible (separador `;`, codificación UTF-8 con BOM, saltos de línea CRLF, coordenadas entre comillas). La definición de categorías, el significado de la fecha de alerta y el sistema de referencia se confirmarán con la entidad responsable.

Anexo 3

Registro de depuración de datos

Tabla 9. *Registro de depuración preliminar.*

Etapa	Registros restantes	Registros excluidos
Registros del CSV disponible (1/1–29/8/2025)	996	—
Tras eliminar duplicados exactos	986	10
Con `fechaalerta` y turno válidos	986	0
Con coordenadas presentes y parseables	986	0
Con CRS validado y ubicación dentro del distrito	Por completar	Por completar
Registros utilizables para el análisis	Por completar (máximo 986)	Por completar

Nota. Conteos del diagnóstico preliminar. Los 70 registros con igual fecha, turno y coordenadas no se excluyen (ver sección 3.3.2). Falta verificar la ubicación frente al polígono distrital.