UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO

FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y MECÁNICA

ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



PLAN DE TESIS

Arquitectura de clústeres espaciales para la caracterización de incidentes de seguridad ciudadana en San Sebastián, Cusco

---

Para optar al título profesional de:
Ingeniero Informático y de Sistemas

Presentado por:
Ronaldo Ticona Jancco

Asesor:
Por designar

CUSCO – PERÚ
2026

RESUMEN

El presente plan propone una arquitectura analítica basada en clústeres espaciales para caracterizar los incidentes de seguridad ciudadana registrados en SIPCOP Municipal en San Sebastián, Cusco. La arquitectura organizará la validación y preparación de los datos, el agrupamiento espacial, la evaluación estadística, el análisis temporal y la generación de resultados cartográficos. Se especificarán sus componentes, interfaces, flujo de datos, reglas de trazabilidad y criterios de aceptación; una prueba de concepto reproducible permitirá evaluar su funcionamiento con el extracto disponible, que contiene 996 registros entre el 1 de enero y el 29 de agosto de 2025. El diagnóstico preliminar muestra coordenadas con resolución aproximada de 110 m y 412 ubicaciones distintas. Para el análisis se propone DBSCAN, comparado con HDBSCAN, y contrastes de agrupamiento frente a modelos nulos espaciales. La prueba de concepto se evaluará mediante casos funcionales, repetición controlada del flujo, consistencia de resultados y cumplimiento de requisitos. Los hallazgos del caso describirán únicamente los registros disponibles; estos incluyen atenciones que no necesariamente constituyen delitos y no cubren la totalidad de incidentes del distrito.

Palabras clave: ocurrencias de seguridad ciudadana, agrupamiento espacial, DBSCAN, *hotspots*, patrullaje municipal, San Sebastián.

ABSTRACT

This proposal presents a spatial-cluster-based analytical architecture for characterizing public-safety incidents recorded in the SIPCOP Municipal system in San Sebastián, Cusco. The architecture will organize data validation and preparation, spatial clustering, statistical assessment, temporal analysis, and cartographic output. Its components, interfaces, data flow, traceability rules, and acceptance criteria will be specified; a reproducible proof of concept will evaluate its operation using the available extract of 996 records dated from 1 January to 29 August 2025. Preliminary diagnostics show coordinates with an approximate resolution of 110 m and 412 distinct locations. DBSCAN, compared with HDBSCAN, and spatial null-model tests are proposed for the case analysis. The proof of concept will be evaluated through functional test cases, controlled workflow reruns, output consistency, and requirements compliance. Findings will describe only the available records, which include attended events that are not necessarily crimes and do not represent all incidents in the district.

Keywords: public security incidents, spatial clustering, DBSCAN, hotspots, municipal patrol, San Sebastián.

AGRADECIMIENTOS

Agradezco a quienes apoyaron el desarrollo de esta investigación: a la Universidad Nacional de San Antonio Abad del Cusco y a la Escuela Profesional de Ingeniería Informática y de Sistemas, por mi formación; a los docentes que orientaron la elaboración de este plan; y a mi familia, por su respaldo constante.

ÍNDICE GENERAL

Resumen I

Abstract II

Agradecimientos III

Índice de figuras VIII

Índice de tablas IX

Índice de algoritmos X

Índice de ecuaciones XI

Índice de anexos XII

Índice de abreviaturas XIII

Índice de símbolos XV

Glosario de términos XVII

Introducción XX

Capítulo I Generalidades 1

1.1 Planteamiento del problema 1

1.1.1 Descripción del problema 1

1.1.2 Identificación del problema 2

1.1.3 Formulación del problema 2

1.1.3.1 Problema general 2

1.1.3.2 Problemas específicos 2

1.2 Objetivos de la investigación 3

1.2.1 Objetivo general 3

1.2.2 Objetivos específicos 3

1.3 Hipótesis de la investigación 3

1.3.1 Hipótesis general 3

1.3.2 Hipótesis específicas 4
1.4 Justificación de la investigación 4
1.5 Alcances y limitaciones 5
1.5.1 Alcances 5
1.5.2 Limitaciones 5
Capítulo II Marco teórico y estado del arte **8**
2.1 Antecedentes y estado del arte 8
2.1.1 Antecedentes internacionales 8
2.1.2 Antecedentes nacionales 9
2.1.3 Antecedentes locales 10
2.1.4 Síntesis y brecha de investigación 10
2.2 Fundamentos teóricos 11
2.2.1 Seguridad ciudadana y concentración del delito 11
2.2.2 Análisis espacial 11
2.2.3 Agrupamiento espacial por densidad 12
2.2.4 Resolución y error de georreferenciación 12
2.2.5 Inferencia sobre concentraciones espaciales y espacio-temporales . 12
2.2.6 Evaluación de la calidad del agrupamiento 13
2.2.7 Arquitectura analítica y evaluación del artefacto 13
2.2.8 Análisis temporal y pruebas estadísticas 14
2.2.9 Visualización geoespacial 15
2.3 Definición de términos básicos 15
Capítulo III Metodología de la investigación **16**
3.1 Enfoque, tipo y diseño de investigación 16
3.1.1 Enfoque de investigación 16
3.1.2 Tipo y alcance de la investigación 16
3.1.3 Diseño de investigación 16
3.2 Definiciones y variables 17
3.2.1 Artefacto de investigación 17

3.2.2 Definiciones operativas 18
3.2.3 Variables y operacionalización 18
3.3 Unidad de análisis, población y muestra 19
3.3.1 Unidad de análisis 19
3.3.2 Población y muestra 19
3.3.3 Diagnóstico preliminar del extracto 20
3.4 Técnicas e instrumentos de recolección 22
3.5 Procedimiento metodológico 23
3.6 Protocolo de evaluación 24
3.6.1 Selección de parámetros y calidad del agrupamiento 24
3.6.2 Comparación entre DBSCAN y HDBSCAN 25
3.6.3 Concentración espacial frente al azar 25
3.6.4 Distribución temporal de los *hotspots* 26
3.6.5 Análisis de sensibilidad 27
3.7 Métodos de análisis de datos 27
3.8 Aspectos éticos y de gestión de datos 28

Capítulo IV Estudio de factibilidad **29**

4.1 Enfoque adoptado 29
4.2 Factibilidad técnica 29
4.2.1 Hardware y cómputo 29
4.2.2 Datos 29
4.2.3 Herramientas y software 30
4.3 Factibilidad económica 30
4.4 Factibilidad operativa 30
4.5 Viabilidad y sostenibilidad 30

Capítulo V Aspectos administrativos **31**

5.1 Cronograma de actividades 31
5.2 Presupuesto y financiamiento 31
5.3 Equipo de investigación 32

Referencias **33**

Anexo 1. Matriz de consistencia **38**

Anexo 2. Ficha de estructura de datos del SIPCOP-M **39**

Anexo 3. Registro de depuración de datos **40**

ÍNDICE DE FIGURAS

Figura 1. Componentes y flujo de datos de la arquitectura analítica propuesta. 17

Figura 2. Ubicaciones distintas del extracto SIPCOP Municipal (San Sebastián, 2025). 21

Figura 3. Volumen de registro y modalidad de exposición a peligro o abandono por mes. 22

ÍNDICE DE TABLAS

Tabla 1. Síntesis de los antecedentes revisados. 10

Tabla 2. Operacionalización de los resultados medidos. 19

Tabla 3. Diagnóstico preliminar del extracto SIPCOP Municipal de San Sebastián. 20

Tabla 4. Cronograma de actividades por semanas (octubre 2026 – febrero 2027). 31

Tabla 5. Presupuesto estimado del proyecto (soles). 32

Tabla 6. Equipo de investigación. 32

Tabla 7. Matriz de consistencia. 38

Tabla 8. Campos del archivo CSV SIPCOP Municipal (19 columnas). 39

Tabla 9. Registro de depuración preliminar. 40

ÍNDICE DE ALGORITMOS

1 DBSCAN aplicado a las ocurrencias georreferenciadas. 24

ÍNDICE DE ECUACIONES

1 Distancia haversine entre dos ocurrencias. 11

2 Estimador de densidad kernel. 11

3 Vecindad ε de un punto en DBSCAN. 12

4 Coeficiente de silueta. 13

5 Estadístico chi-cuadrado de Pearson. 14

6 Valor p Monte Carlo de un grupo espacial. 26

7 Coeficiente V de Cramér. 27

ÍNDICE DE ANEXOS

1 Matriz de consistencia 38

2 Ficha de estructura de datos del SIPCOP-M 39

3 Registro de depuración de datos 40

ÍNDICE DE ABREVIATURAS

ARI	índice de Rand ajustado (*Adjusted Rand Index*).
CRISP-DM	proceso estándar para minería de datos (*Cross-Industry Standard Process for Data Mining*).
CSR	aleatoriedad espacial completa (*complete spatial randomness*).
DBSCAN	agrupamiento espacial basado en densidad con ruido (*Density-Based Spatial Clustering of Applications with Noise*).
ENAPRES	Encuesta Nacional de Programas Presupuestales.
HDBSCAN	agrupamiento jerárquico basado en densidad (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*).
PNP	Policía Nacional del Perú.
SIPCOP-M	sistema de registros de ocurrencias de seguridad atendidas por el serenazgo de la Municipalidad Distrital de San Sebastián.

UNSAAC	Universidad Nacional de San Antonio Abad del Cusco.
WGS84	Sistema Geodésico Mundial 1984 (*World Geodetic System 1984*).

ÍNDICE DE SÍMBOLOS

α	Nivel de significancia.
H_1	Hipótesis alterna.
h	Ancho de banda del estimador de densidad kernel.
$b(i)$	Distancia media del punto i al grupo vecino más cercano.
χ^2	Estadístico chi-cuadrado de Pearson.
m_j	Número de ocurrencias del grupo espacial j.
V	Coeficiente V de Cramér, medida del tamaño del efecto.
$\hat{f}(x)$	Densidad estimada de incidentes en la ubicación x.
$d(p,q)$	Distancia entre los puntos p y q.
R	Radio medio de la Tierra, aproximadamente 6371 km.
ε	Radio de vecindad de DBSCAN, distancia máxima entre dos puntos vecinos.
E_i	Frecuencia esperada de la categoría i.

$K(\cdot)$	Función kernel.
M_b	Tamaño del mayor grupo en la simulación b.
φ	Latitud expresada en radianes.
λ	Longitud expresada en radianes.
MinPts	Número mínimo de puntos dentro del radio epsilon para considerar un punto como núcleo.
$N_\varepsilon(p)$	Conjunto de puntos a distancia menor o igual que epsilon del punto p.
H_0	Hipótesis nula.
O_i	Frecuencia observada de la categoría i.
p_j	Valor p Monte Carlo del grupo j.
$s(i)$	Coeficiente de silueta del punto i.
B	Número de simulaciones Monte Carlo.
$a(i)$	Distancia media del punto i a los puntos de su grupo.

GLOSARIO DE TÉRMINOS

Agrupamiento espacial	Técnica que reúne eventos geográficamente cercanos según criterios de proximidad o densidad.
Arquitectura analítica	Estructura lógica de componentes, responsabilidades, interfaces y flujos que organiza el procesamiento y la generación de resultados.
Densidad kernel	Método que estima una superficie continua de intensidad a partir de puntos, ponderando cada evento según su distancia.
Georreferenciación	Asignación de coordenadas geográficas a un registro para ubicarlo en un sistema de referencia espacial.
Grupo espacial (clúster)	Conjunto de ocurrencias que un algoritmo de agrupamiento reúne por proximidad o densidad.
Haversine	Fórmula para calcular la distancia sobre una esfera entre dos puntos dados por latitud y longitud.
Hotspot	Grupo espacial cuya cantidad de ocurrencias supera lo esperado bajo el modelo nulo estadístico definido.

Incidente de seguridad ciudadana	En esta investigación, ocurrencia de seguridad atendida y registrada por el patrullaje municipal e integrado; no necesariamente constituye un delito.
Mapa de calor	Representación cartográfica mediante gradientes de color para mostrar la intensidad de un fenómeno.
MinPts	Parámetro de DBSCAN que fija el mínimo de puntos requeridos en la vecindad para formar un grupo.
Prueba de concepto	Implementación acotada que demuestra y permite evaluar el funcionamiento de los componentes esenciales de la arquitectura.
Ruido	Puntos que DBSCAN no asigna a ningún grupo por estar en zonas de baja densidad.
Serenazgo	Servicio municipal de seguridad ciudadana que realiza patrullaje y prevención en el distrito.
Trazabilidad	Capacidad de relacionar requisitos, componentes, transformaciones, parámetros, pruebas y resultados de cada ejecución.
Turno	Franja horaria de operación del serenazgo, por ejemplo mañana, tarde o noche.

Épsilon (ε)	Parámetro de DBSCAN que define el radio de búsqueda de vecinos alrededor de un punto.

INTRODUCCIÓN

La seguridad ciudadana es una de las principales demandas de la población peruana y una responsabilidad de gestión de los gobiernos locales. En la región Cusco, los registros de la Policía Nacional del Perú (PNP) muestran un aumento de las denuncias por homicidio, y la Encuesta Nacional de Programas Presupuestales (ENAPRES) sitúa al departamento entre los de mayor percepción de inseguridad del país (Instituto Nacional de Estadística e Informática, 2023). Sin embargo, los hechos no se distribuyen de manera uniforme: tienden a concentrarse en ciertos lugares y momentos (Chainey & Ratcliffe, 2005; Eck et al., 2005; Weisburd, 2015), de modo que gestionarlos exige decidir dónde y cuándo intervenir, y no solo con qué recursos.

Para estudiar esa concentración se emplean mapas de calor, estimación de densidad kernel y técnicas de agrupamiento espacial (Chainey & Ratcliffe, 2005; Chainey et al., 2008). agrupamiento espacial basado en densidad con ruido (*Density-Based Spatial Clustering of Applications with Noise*) (DBSCAN) (Ester et al., 1996) agrupa las ocurrencias según su densidad, no exige fijar el número de grupos y deja como ruido los puntos aislados; agrupamiento jerárquico basado en densidad (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*) (HDBSCAN) (Campello et al., 2013) extiende la idea a una jerarquía de densidades. Ambos dependen de parámetros cuya elección condiciona los grupos obtenidos, por lo que deben justificarse y verificarse (Schubert et al., 2017). Además, que un algoritmo devuelva un grupo no demuestra que su concentración supere lo esperable por azar, y esa distinción es central en este plan.

El método ya se ha aplicado en el Perú (Cutid-Aguero et al., 2025), pero el extracto de ocurrencias del patrullaje municipal e integrado de San Sebastián se encuentra disponible como registros tabulares y carece de un flujo analítico local documentado que integre validación, agrupamiento, evaluación y presentación reproducible. Esta brecha es provisional y se contrasta con la revisión del Capítulo II.

Por ello, el propósito de esta investigación es especificar y evaluar una arquitectura

de clústeres espaciales que integre las etapas de validación y preparación de datos, agrupamiento, evaluación estadística, caracterización temporal y presentación cartográfica. Se desarrollará una prueba de concepto reproducible y se aplicará al extracto disponible de sistema de registros de ocurrencias de seguridad atendidas por el serenazgo de la Municipalidad Distrital de San Sebastián (SIPCOP-M), con 996 registros y fechas de alerta entre el 1 de enero y el 29 de agosto de 2025. El caso permitirá evaluar DBSCAN, compararlo con HDBSCAN y describir las concentraciones y sus distribuciones por turno, día de la semana y mes. El diagnóstico preliminar indica que las coordenadas tienen una resolución aproximada de 110 m (412 ubicaciones distintas en 996 registros), lo que condiciona el radio de agrupamiento; además, la tasa de registros cambia entre meses. La fecha de alerta no se asumirá como fecha exacta del hecho sin confirmar su definición. El producto de investigación será la arquitectura especificada y su prueba de concepto, no una plataforma municipal desplegada. Los resultados del caso se limitarán al extracto disponible y no presupondrán que existan concentraciones significativas.

El plan se organiza en cinco capítulos: Generalidades (I), Marco teórico y estado del arte (II), Metodología (III), Estudio de factibilidad (IV) y Aspectos administrativos (V). Al final se incluyen las referencias y los anexos.

CAPÍTULO I

GENERALIDADES

1.1. Planteamiento del problema

1.1.1. Descripción del problema

La región Cusco enfrenta un incremento sostenido en la percepción de inseguridad ciudadana y en la ocurrencia de hechos delictivos. Según registros de la PNP, las denuncias por homicidio en el departamento de Cusco aumentaron de 36 casos en 2022 a 60 casos en 2024 (enero-noviembre) (Policía Nacional del Perú, 2024). Asimismo, la ENAPRES ubicó a Cusco entre los departamentos con mayor porcentaje de percepción de inseguridad del país, con un 92,3 % durante el periodo noviembre 2022-abril 2023 (Instituto Nacional de Estadística e Informática, 2023).

La literatura criminológica documenta que el delito no se reparte al azar: una proporción reducida de lugares concentra una parte desproporcionada de los hechos (Sherman et al., 1989; Weisburd, 2015). Por ello, los gobiernos locales, que participan en el Sistema Nacional de Seguridad Ciudadana a través de los comités distritales (Congreso de la República del Perú, 2003), necesitan saber en qué zonas y en qué momentos se concentran los incidentes para orientar el patrullaje.

El Mapa del Delito Georreferenciado del Ministerio del Interior publica una capa denominada SIPCOP Municipal con registros de ocurrencias del patrullaje municipal e integrado (serenazgo y patrullaje local integrado). El extracto disponible para el distrito de San Sebastián contiene 996 registros entre el 1 de enero y el 29 de agosto de 2025, con categoría, turno y coordenadas. Estos datos ofrecen un caso para especificar y evaluar una arquitectura analítica que integre su validación, procesamiento espacial, agrupamiento y presentación de resultados. El campo temporal disponible es la fecha de alerta; no se cuenta con hora individual en el archivo descargado. Las coordenadas están en grados decimales con tres decimales (unos 110 m), de modo que los 996 registros se reducen a 412 ubicaciones distintas.

1.1.2. Identificación del problema

La principal dificultad es la ausencia de una arquitectura documentada y reproducible que convierta los registros disponibles de SIPCOP Municipal en resultados espaciales y temporales trazables para la gestión local. Un análisis aislado de los datos no resuelve cómo integrar la recepción y validación de registros, la preparación de coordenadas, la selección y comparación de algoritmos, la evaluación estadística de las concentraciones y la generación de salidas cartográficas. La arquitectura debe además considerar las limitaciones del extracto: 996 registros fechados entre enero y agosto de 2025, sin hora individual y con coordenadas de resolución aproximada de 110 m. El periodo no representa los años 2022-2024 ni los últimos meses de 2025.

1.1.3. Formulación del problema

1.1.3.1. Problema general

¿Cómo debe estructurarse y evaluarse una arquitectura basada en clústeres espaciales para caracterizar los incidentes de seguridad ciudadana registrados en SIPCOP Municipal en San Sebastián, Cusco?

1.1.3.2. Problemas específicos

PE1. ¿Qué requisitos funcionales, de datos y de calidad debe atender la arquitectura, dadas las características del extracto SIPCOP-M?

PE2. ¿Qué componentes, interfaces y flujo de procesamiento deben conformar la arquitectura para integrar la validación de datos, el agrupamiento espacial y el análisis temporal?

PE3. ¿Cómo implementar una prueba de concepto que ejecute el flujo arquitectónico con técnicas de agrupamiento espacial y produzca resultados reproducibles?

PE4. ¿En qué medida la arquitectura y su prueba de concepto cumplen los requisitos funcionales y los criterios de calidad definidos?

1.2. Objetivos de la investigación

1.2.1. Objetivo general

Desarrollar y evaluar una arquitectura analítica basada en clústeres espaciales para caracterizar los incidentes de seguridad ciudadana registrados en SIPCOP Municipal en San Sebastián, Cusco, mediante una prueba de concepto reproducible aplicada al extracto disponible.

1.2.2. Objetivos específicos

OE1. Analizar las características y calidad del extracto SIPCOP-M y especificar los requisitos funcionales, de datos y de calidad de la arquitectura.

OE2. Diseñar la arquitectura, definiendo sus componentes, interfaces, flujo de datos y mecanismos de trazabilidad para el procesamiento espacial y temporal.

OE3. Implementar una prueba de concepto que integre la preparación de datos, DBSCAN, la comparación con HDBSCAN, los contrastes estadísticos y la generación de resultados cartográficos.

OE4. Evaluar la prueba de concepto frente a los requisitos y criterios de aceptación definidos, considerando funcionalidad, reproducibilidad, calidad de resultados y limitaciones del conjunto de datos.

1.3. Hipótesis de la investigación

1.3.1. Hipótesis general

H_G: La arquitectura analítica propuesta, implementada como prueba de concepto, permitirá ejecutar de forma trazable y reproducible el flujo de validación, agrupamiento espacial, análisis temporal y presentación de resultados para el extracto SIPCOP-M de San Sebastián, de acuerdo con los requisitos y criterios de aceptación establecidos.

1.3.2. Hipótesis específicas

H_1: Los requisitos funcionales, de datos y de calidad definidos podrán vincularse con componentes y pruebas de aceptación explícitos en una matriz de trazabilidad completa.

H_2: La arquitectura especificará todos los componentes, interfaces y transformaciones necesarios para ejecutar el flujo desde la entrada del extracto hasta la generación de resultados espaciales y temporales.

H_3: La prueba de concepto procesará el extracto conforme a las reglas de validación, transformación y trazabilidad especificadas, y generará resultados reproducibles al repetir la ejecución con los mismos datos, parámetros y configuración.

H_4: La evaluación de la prueba de concepto demostrará el cumplimiento de los criterios de aceptación definidos antes de la ejecución, sin exclusiones de registros ni parámetros no documentados.

Las hipótesis se evaluarán mediante pruebas funcionales, repetición controlada del flujo y verificación de los productos generados; la existencia de concentraciones significativas no se presupone y constituye un resultado del caso de aplicación, no una condición de éxito de la arquitectura.

1.4. Justificación de la investigación

Justificación científica. La investigación aportará una arquitectura analítica reproducible para integrar métodos de agrupamiento espacial, evaluación estadística y caracterización temporal en registros administrativos de seguridad ciudadana, documentando sus supuestos y límites mediante un caso local.

Justificación metodológica. El estudio especificará componentes, interfaces, flujo de datos, reglas de trazabilidad y criterios de aceptación, y probará el flujo con un artefacto reproducible. Así se podrá distinguir la calidad de la arquitectura de los resultados particulares obtenidos en el extracto.

Justificación tecnológica. La prueba de concepto integrará herramientas de código abierto para convertir datos tabulares del SIPCOP-M en resultados espaciales y temporales verificables. La arquitectura será independiente de una plataforma institucional específica

y podrá servir de referencia para futuras implementaciones, sin afirmar que constituye un sistema de producción.

Justificación social y práctica. La Municipalidad Distrital dispondrá de información sobre zonas críticas y momentos de mayor recurrencia para focalizar el patrullaje y la prevención del serenazgo. El estudio no mide el efecto de ninguna intervención sobre la reducción del delito.

1.5. Alcances y limitaciones

1.5.1. Alcances

Alcance espacial. Distrito de San Sebastián, provincia y departamento de Cusco.

Alcance temporal. Registros con fecha de alerta entre el 1 de enero y el 29 de agosto de 2025, según el extracto disponible al preparar el estudio.

Alcance tecnológico. Especificación de una arquitectura analítica lógica; prototipo de prueba de concepto con ingesta local de archivos, validación y preparación de datos, agrupamiento con DBSCAN y comparación con HDBSCAN, contraste espacial y análisis temporal, generación de salidas tabulares y cartográficas, trazabilidad de parámetros y pruebas de aceptación. No incluye despliegue institucional ni integración en producción.

Alcance disciplinar. Ciencia de datos y análisis geoespacial, dentro de la Ingeniería Informática y de Sistemas.

1.5.2. Limitaciones

Calidad y cobertura del registro. El análisis se limita a 996 filas del extracto público descargado. Se evaluarán coordenadas, categorías, duplicados y otros problemas de calidad; los resultados no cubren registros no incluidos en ese extracto. El archivo no trae un identificador único de ocurrencia, por lo que los duplicados no pueden confirmarse, y todos los registros pertenecen a un mismo genérico (alertas tempranas en apoyo a la PNP), por lo que el extracto parece ser un subconjunto de la actividad total.

Resolución espacial. Las coordenadas tienen tres decimales (unos 110 m): hay 412 ubicaciones distintas y el 77 % de los registros comparte coordenada exacta con otro. Es pro-

bable que parte de las ubicaciones proceda de una geocodificación por puntos de referencia (por ejemplo, paraderos o el cementerio) y no de la posición real del hecho; los resultados no se interpretarán a escalas menores que esa resolución.

Estabilidad del registro en el tiempo. Los registros por día varían de 2,0 (junio) a 7,5 (agosto); hay 26 de 241 días sin ningún registro (no se sabe si hubo cero eventos o falta de reporte) y la modalidad de "exposición a peligro o abandono de personas" pasa del 57 % de los registros en enero a 9–17 % de junio a agosto, lo que sugiere un cambio de clasificación o de práctica de registro. Las diferencias entre meses pueden reflejar el registro y no el fenómeno.

Cobertura temporal. El conjunto disponible abarca del 1 de enero al 29 de agosto de 2025. No permite describir 2022-2024, el último cuatrimestre de 2025 ni inferir un patrón anual completo.

Resolución temporal. El archivo contiene fecha de alerta y turno, pero no hora individual de ocurrencia; por ello no se analizarán patrones horarios y la fecha de alerta puede no coincidir exactamente con la del hecho.

Registro de lo atendido, no de lo ocurrido. La capa SIPCOP Municipal documenta ocurrencias registradas por el patrullaje municipal e integrado (el 51 % de los registros proviene de Patrullaje Local Integrado), que incluyen hechos de seguridad que no son necesariamente delitos (el 34 % corresponde a exposición a peligro o abandono de personas); no incluye los hechos no reportados ni los denunciados solo ante la Policía Nacional. Los patrones describen lo registrado en la capa y no la totalidad del delito ni necesariamente todos los servicios atendidos.

Precisión de la ubicación. La exactitud de las coordenadas depende del modo de registro y condiciona la elección del radio ε.

Sensibilidad a los parámetros. Los grupos obtenidos con DBSCAN dependen de ε y MinPts; se documentará un análisis de sensibilidad.

Alcance inferencial. El diseño es observacional: los resultados describen patrones y no establecen causas ni son generalizables a otros distritos. El registro refleja también dónde y cuándo se patrulla: el 76 % de los registros nace del patrullaje y solo 232 proceden de

llamadas ciudadanas, alarmas o mensajería, lo que puede inflar la presencia de ocurrencias en zonas y turnos con mayor cobertura. Este sesgo se mide con un análisis de sensibilidad por origen del registro.

CAPÍTULO II

MARCO TEÓRICO Y ESTADO DEL ARTE

2.1. Antecedentes y estado del arte

La revisión que sigue es preliminar: reúne fundamentos de análisis espacial y de arquitectura de software para justificar el diseño y evaluación del artefacto propuesto. Deberá actualizarse con una búsqueda sistemática antes de la sustentación.

2.1.1. Antecedentes internacionales

Sherman et al. (1989) analizaron las llamadas a la policía en Minneapolis y mostraron que una fracción reducida de las direcciones concentraba una parte desproporcionada de los incidentes, lo que dio sustento empírico a la noción de *hot spot*. Weisburd (2015) generalizó este resultado como la "ley de la concentración del delito": en distintas ciudades, un porcentaje pequeño de microlugares reúne cerca de la mitad de los hechos y esa concentración es estable en el tiempo. Ambos trabajos justifican analizar el delito por lugares y no solo por unidades administrativas amplias.

En cuanto a los métodos, Chainey et al. (2008) compararon técnicas de mapeo de *hotspots* según su capacidad de anticipar la localización de delitos futuros y encontraron que la densidad kernel tuvo un desempeño predictivo competitivo frente a otras técnicas. Hu et al. (2018) propusieron un marco de densidad kernel espacio-temporal para la elaboración de mapas predictivos de *hotspots* y su evaluación, lo que muestra la utilidad de incorporar el tiempo junto con el espacio. Estos estudios sustentan el uso de la densidad kernel como visualización complementaria, pero no resuelven cómo delimitar grupos discretos de ocurrencias.

Estudios recientes muestran la diversidad de escalas y técnicas usadas en cartografía delictiva. Ristea y Leitner (2020) aplicaron sistemas de información geográfica al análisis urbano del delito; Hajela et al. (2020) estudiaron la identificación de zonas críticas mediante

agrupamiento; y Masron et al. (2021) compararon la distribución de zonas críticas en dos distritos de Malasia. Para datos espaciotemporales, Choi y Hong (2021) propusieron una variante de DBSCAN para clustering multidimensional, mientras que Xie et al. (2021) incorporaron inferencia estadística al agrupamiento basado en densidad. Otros trabajos exploran clustering jerárquico y modelos difusos para cartografía y propagación de concentraciones delictivas (Cardone & Di Martino, 2022; Gustriansyah et al., 2022). Estos antecedentes muestran que la selección del algoritmo debe responder al tipo de dato y que el resultado algorítmico debe distinguirse de la evidencia estadística.

Como referencias metodológicas recientes, Medina Ariza y Solymosi (2023b) presentan métodos de patrones puntuales para eventos delictivos y Medina Ariza y Solymosi (2023c) discuten la dimensión temporal del mapeo del delito; Medina Ariza y Solymosi (2023a) abordan la detección de concentraciones y repeticiones. Estos aportes orientan la separación entre descripción cartográfica, análisis de patrones y evaluación de concentraciones.

2.1.2. Antecedentes nacionales

Cutid-Aguero et al. (2025) analizaron el delito en la Provincia Constitucional del Callao (febrero de 2024) con minería de datos espaciales: emplearon densidad kernel para visualizar *hotspots* y DBSCAN, con ε seleccionado mediante el gráfico de k-distancias, para detectar grupos discretos. Reportan una fuerte concentración geográfica de los incidentes y un grupo de 317 ocurrencias en el Cercado del Callao, y concluyen que el delito sigue patrones geográficos definidos. Es el antecedente más cercano a este plan por la técnica y por el contexto peruano.

Mamani Ramos (2019) desarrolló un sistema de geo-sectorización de zonas delictivas con el algoritmo K-Means y visualización en mapas, aplicado al contexto turístico y con datos abiertos de Buenos Aires. K-Means exige fijar el número de grupos de antemano y asigna todos los puntos a un grupo, a diferencia de DBSCAN, que admite ruido y formas arbitrarias.

2.1.3. Antecedentes locales

En la búsqueda preliminar no se identificaron estudios publicados que apliquen técnicas de agrupamiento espacial a registros de serenazgo del distrito de San Sebastián o de la ciudad del Cusco. Esta afirmación es provisional y se confirmará con una búsqueda en los repositorios institucionales (Universidad Nacional de San Antonio Abad del Cusco (UNSAAC), ALICIA y RENATI).

2.1.4. Síntesis y brecha de investigación

La Tabla 1 resume los antecedentes sobre concentración y análisis espacial. Estos métodos aportan algoritmos para detectar grupos, pero no especifican por sí mismos cómo integrar las fuentes, validaciones, transformaciones, parámetros, pruebas y productos en un flujo reproducible. La brecha que aborda este plan es la falta de una arquitectura analítica documentada y evaluada para caracterizar los incidentes registrados en SIPCOP-M de San Sebastián, considerando sus restricciones de calidad, resolución espacial y cobertura temporal. La existencia de grupos o concentraciones significativas no se presupone.

Tabla 1. *Síntesis de los antecedentes revisados.*

Estudio	**Técnica**	**Aporte**	**Limitación respecto de este plan**
Sherman et al. (1989)	Conteo por dirección	Concentración del delito en pocos lugares	No usa agrupamiento algorítmico
Weisburd (2015)	Concentración en microlugares	Regularidad de la concentración y estabilidad temporal	Otro contexto y escala
Chainey et al. (2008)	Comparación de mapeo de *hotspots*	Desempeño predictivo de la densidad kernel	No delimita grupos discretos
Hu et al. (2018)	Densidad kernel espacio-temporal	Mapas predictivos y su evaluación	Otro contexto; fines predictivos
Cutid-Aguero et al. (2025)	Densidad kernel y DBSCAN	Aplicación en el Callao, ε por k-distancias	Otra jurisdicción; un solo mes
Mamani Ramos (2019)	K-Means	Geo-sectorización con datos de Buenos Aires	Número de grupos fijo; sin ruido

Nota. Elaboración propia.

2.2. Fundamentos teóricos

2.2.1. Seguridad ciudadana y concentración del delito

La seguridad ciudadana designa la protección de las personas frente a hechos que amenazan su integridad y sus bienes, y en el Perú se organiza como un sistema con participación de los gobiernos locales (Congreso de la República del Perú, 2003). El serenazgo es el servicio municipal que realiza patrullaje y prevención en el distrito. La teoría de las actividades rutinarias sostiene que el delito se produce cuando coinciden en el espacio y el tiempo un ofensor motivado, un objetivo adecuado y la ausencia de guardianes (Cohen & Felson, 1979); de ello se sigue que los incidentes tiendan a agruparse en ciertos lugares y horarios, y que esa regularidad pueda estudiarse mediante mapas y estadística (Eck et al., 2005; Weisburd, 2015).

2.2.2. Análisis espacial

El análisis espacial estudia la distribución geográfica de los eventos, su densidad y su agrupamiento (Chainey & Ratcliffe, 2005). Una vez confirmada la georreferenciación y que las coordenadas del archivo pueden transformarse al sistema Sistema Geodésico Mundial 1984 (*World Geodetic System 1984*) (WGS84), la distancia entre dos ocurrencias se calculará con la fórmula haversine (Sinnott, 1984):

$$d(p,q) = 2R \arcsin \sqrt{\sin^2\left(\frac{\varphi_q - \varphi_p}{2}\right) + \cos\varphi_p \cos\varphi_q \sin^2\left(\frac{\lambda_q - \lambda_p}{2}\right)} \tag{1}$$

donde R es el radio medio de la Tierra, φ la latitud y λ la longitud, ambas en radianes.

La densidad de eventos en una ubicación x puede estimarse mediante densidad kernel (Silverman, 1986):

$$\hat{f}(x) = \frac{1}{nh^2} \sum_{i=1}^{n} K(\cdot)\left(\frac{x - x_i}{h}\right) \tag{2}$$

donde n es el número de ocurrencias, h el ancho de banda y $K(\cdot)$ la función kernel. La densidad kernel produce una superficie continua apta para mapas de calor, pero no delimita grupos de ocurrencias; en este estudio se usa solo como visualización.

2.2.3. Agrupamiento espacial por densidad

DBSCAN (Ester et al., 1996) agrupa los puntos según su densidad a partir de la vecindad de cada uno:

$$N_\varepsilon(p) = \{\, q \in D \mid d(p,q) \leq \varepsilon \,\} \tag{3}$$

Un punto es *núcleo* si $|N_\varepsilon(p)| \geq \text{MinPts}$; los puntos alcanzables desde un núcleo forman un grupo espacial, y los restantes se etiquetan como ruido. El método no requiere fijar el número de grupos, admite formas arbitrarias y es sensible a ε y MinPts (Schubert et al., 2017). Una guía habitual para elegir ε es el gráfico de k-distancias, donde se busca el "codo" de la curva ordenada de distancias al k-ésimo vecino. HDBSCAN (Campello et al., 2013; McInnes et al., 2017) extiende la idea a una jerarquía de densidades y no requiere fijar ε, aunque sí un tamaño mínimo de grupo.

2.2.4. Resolución y error de georreferenciación

Las coordenadas de los registros policiales suelen proceder de la geocodificación de direcciones o de puntos de referencia, y su error posicional afecta la detección de concentraciones; por eso se recomienda informar la proporción de registros georreferenciados y la precisión lograda (Ratcliffe, 2004). Cuando las coordenadas están redondeadas a una malla, varios registros comparten la misma ubicación y las distancias menores que el paso de la malla no son observables. En consecuencia, el radio ε de DBSCAN no debe ser menor que ese paso, los puntos coincidentes se cuentan como registros distintos al evaluar MinPts y la simulación del modelo nulo debe reproducir la misma cuantización.

2.2.5. Inferencia sobre concentraciones espaciales y espacio-temporales

Un grupo devuelto por un algoritmo no demuestra por sí solo una concentración mayor que la esperable por azar. Para contrastarla se dispone de simulaciones Monte Carlo del tamaño de los grupos bajo un modelo nulo, de la función K de Ripley (Ripley, 1976), que describe el agrupamiento a distintas escalas, y del estadístico de escaneo espacial de Kulldorff (Kulldorff, 1997), que busca ventanas con exceso de casos frente a una población de refe-

rencia. La interacción entre espacio y tiempo puede evaluarse con la prueba de Knox (Knox, 1964). En este plan el contraste principal es la simulación Monte Carlo de la sección 3.6.3; la función K y el escaneo de Kulldorff se consideran contrastes complementarios.

2.2.6. Evaluación de la calidad del agrupamiento

El coeficiente de silueta (Rousseeuw, 1987) compara, para cada punto i, la distancia media a los puntos de su grupo, $a(i)$, con la distancia media al grupo vecino más cercano, $b(i)$:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \qquad -1 \leq s(i) \leq 1 \tag{4}$$

Valores cercanos a 1 indican grupos compactos y bien separados. Como DBSCAN deja puntos sin grupo, la silueta se calcula sobre los puntos asignados y se informa junto con el porcentaje de ruido y el número de grupos.

2.2.7. Arquitectura analítica y evaluación del artefacto

Una arquitectura de software describe las estructuras relevantes de un sistema, sus elementos, relaciones y principios que orientan su evolución; no equivale únicamente a un diagrama ni a la implementación de una aplicación. La norma ISO/IEC/IEEE 42010 establece conceptos y requisitos para describir arquitecturas mediante interesados, preocupaciones, puntos de vista y vistas (International Organization for Standardization & Institute of Electrical and Electronics Engineers, 2022). Para este estudio, la arquitectura será lógica y analítica: especificará módulos, responsabilidades, interfaces, flujo de datos y decisiones de procesamiento, sin comprometer un despliegue institucional.

La investigación en ciencia del diseño exige identificar explícitamente el artefacto y distinguirlo del problema y del método empleados para construirlo. Weigand et al. (2021) proponen una ontología para describir artefactos de investigación; Weigand y Johannesson (2023) ofrecen criterios para identificar el artefacto en estudios de sistemas de información. Además, Barata et al. (2023) señalan la importancia de informar limitaciones en este tipo de investigación, y Schäffer y Leyh (2025) proponen seleccionar métodos de evaluación adecuados a los objetivos y al artefacto. Estos criterios respaldan que este plan describa la

arquitectura, la prueba de concepto y sus límites como productos diferenciados.

La calidad del artefacto se evaluará respecto de atributos observables y criterios definidos antes de las pruebas. ISO/IEC 25010 proporciona un modelo de calidad de producto que organiza características y subcaracterísticas para especificar y evaluar sistemas y productos de software (International Organization for Standardization, 2023); Argotti et al. (2024) ejemplifican cómo operacionalizar modelos de calidad ISO 25000 para evaluar software. En esta investigación se seleccionarán los atributos pertinentes al alcance: adecuación funcional, confiabilidad de ejecución, mantenibilidad modular y reproducibilidad de resultados. La evaluación combinará trazabilidad entre requisitos y componentes, casos funcionales con entradas válidas e inválidas, repetición controlada del flujo y comprobación de los productos generados.

El proceso de construcción seguirá una lógica de investigación en ciencia del diseño: identificar el problema, definir objetivos de solución, diseñar y desarrollar el artefacto, demostrar su uso y evaluarlo frente a los objetivos establecidos (Peffers et al., 2007). El extracto SIPCOP-M servirá como caso demostrativo, mientras que los resultados de agrupamiento serán evidencia del funcionamiento de módulos analíticos y no una prueba autónoma de calidad arquitectónica.

2.2.8. Análisis temporal y pruebas estadísticas

Para contrastar si la frecuencia de ocurrencias por categoría temporal (turno, día de la semana, mes) difiere de la esperada se utiliza la prueba chi-cuadrado de Pearson (Pearson, 1900). En la prueba de homogeneidad, H_0 establece que las distribuciones comparadas coinciden y H_1 que difieren:

$$\chi^2 = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i} \tag{5}$$

donde O_i y E_i son las frecuencias observada y esperada de la categoría i. La prueba es fiable cuando las frecuencias esperadas no son demasiado pequeñas (Cochran, 1954). Su magnitud depende del tamaño de muestra, por lo que se complementa con el coeficiente V de Cramér (Cramér, 1946) como medida del tamaño del efecto.

2.2.9. Visualización geoespacial

Los mapas de calor, los mapas de puntos con grupos y los tableros permiten comunicar la distribución espacial y temporal de los incidentes a quienes toman decisiones operativas (Chainey & Ratcliffe, 2005). En este estudio se emplearán para presentar los *hotspots* identificados y para facilitar su interpretación por el personal de la municipalidad.

2.3. Definición de términos básicos

Ocurrencia de seguridad ciudadana: hecho atendido y registrado por el patrullaje municipal e integrado (serenazgo y Patrullaje Local Integrado), con fecha, turno, tipo y ubicación; no todos son delitos.

Grupo espacial (clúster): conjunto de ocurrencias agrupadas por un algoritmo según su densidad.

Hotspot: grupo espacial cuya concentración de ocurrencias supera la esperada por azar según un contraste estadístico.

Georreferenciación: asignación de coordenadas a un registro para ubicarlo en un sistema de referencia espacial.

Ruido: punto que DBSCAN no asigna a ningún grupo por hallarse en una zona de baja densidad.

Turno: franja horaria de operación del serenazgo (mañana, tarde y noche).

Aleatoriedad espacial completa (aleatoriedad espacial completa (*complete spatial randomness*) (CSR) modelo en el que los puntos se distribuyen de forma independiente y uniforme en el área de estudio; sirve de referencia nula mínima; no incorpora población, vías ni patrullaje.

CAPÍTULO III

METODOLOGÍA DE LA INVESTIGACIÓN

3.1. Enfoque, tipo y diseño de investigación

3.1.1. Enfoque de investigación

La investigación tiene un enfoque cuantitativo y tecnológico: especifica una arquitectura analítica y la evalúa mediante una prueba de concepto que procesa datos numéricos de ocurrencias (coordenadas, fecha, turno) con procedimientos computacionales y pruebas estadísticas (Hernández-Sampieri & Mendoza, 2018).

3.1.2. Tipo y alcance de la investigación

Es de tipo aplicado y de alcance tecnológico-descriptivo. El artefacto es una arquitectura analítica basada en clústeres espaciales, especificada mediante componentes, interfaces, flujo de datos y criterios de aceptación, junto con una prueba de concepto reproducible. El extracto SIPCOP-M funciona como caso de aplicación para verificar el flujo y caracterizar sus resultados; los contrastes estadísticos son parte de la arquitectura, no el único producto de la investigación. No se busca explicar causas ni desplegar un sistema institucional.

3.1.3. Diseño de investigación

El trabajo adopta un proceso de construcción y evaluación de un artefacto tecnológico, con un caso de aplicación retrospectivo y no experimental: se procesan registros fechados entre el 1 de enero y el 29 de agosto de 2025 sin manipular las variables del fenómeno. El proceso combina las fases de comprensión del problema y los datos, especificación de requisitos, diseño de la arquitectura, implementación de la prueba de concepto, evaluación y comunicación de resultados; el flujo analítico se apoya en las fases de proceso estándar para minería de datos (*Cross-Industry Standard Process for Data Mining*) (CRISP-DM) (Chapman et al., 2000) (Figura 1).

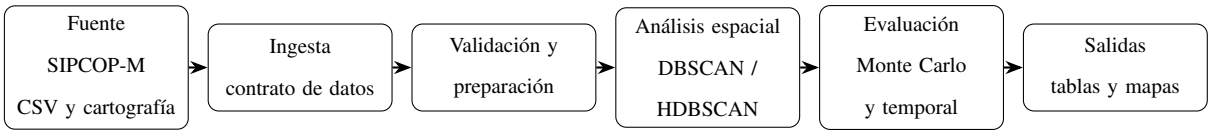


Figura 1. *Componentes y flujo de datos de la arquitectura analítica propuesta.*

Nota. Elaboración propia, con base en el flujo analítico de CRISP-DM (Chapman et al., 2000).

3.2. Definiciones y variables

3.2.1. Artefacto de investigación

El artefacto será una arquitectura analítica lógica, independiente de una plataforma institucional específica, que describirá: (i) fuentes y recepción de datos; (ii) validación, normalización y registro de incidencias de calidad; (iii) almacenamiento de datos preparados y parámetros de ejecución; (iv) procesamiento espacial y temporal, con DBSCAN, comparación HDBSCAN y contrastes; y (v) presentación de tablas, indicadores y mapas. Para cada componente se documentarán propósito, entradas, salidas, dependencias, errores controlados y mecanismos de trazabilidad. La prueba de concepto implementará el flujo con archivos locales y herramientas de código abierto; no incluirá despliegue, autenticación multiusuario ni integración en producción con SIPCOP-M.

La Figura 1 representa el flujo principal y los límites de los componentes. La arquitectura conservará los datos originales sin modificación, generará una versión preparada y registrará parámetros y exclusiones junto con cada ejecución. El componente de análisis recibirá únicamente datos validados; sus resultados alimentarán los contrastes estadísticos y, finalmente, las salidas cartográficas y tabulares.

La evaluación considerará una matriz de trazabilidad requisito-componente-prueba, casos funcionales con entradas válidas e inválidas, repetición del proceso con iguales datos y parámetros, verificación de resultados frente a cálculos de control y medición del tiempo de procesamiento en el extracto de estudio. Los criterios de aceptación serán: (i) el 100 % de los requisitos funcionales prioritarios estará vinculado al menos a un componente y a una prueba; (ii) el 100 % de las filas de entrada terminará como registro procesado o exclusión con motivo; (iii) todas las pruebas de control del flujo y de los algoritmos producirán el

resultado esperado; y (iv) dos ejecuciones con los mismos datos, parámetros y semilla producirán asignaciones y tablas idénticas. El tiempo se medirá y reportará, sin fijar un umbral de rendimiento no justificado por la escala del caso. La revisión de un especialista podrá complementar, pero no sustituir, las pruebas reproducibles.

3.2.2. Definiciones operativas

Incidente de seguridad ciudadana: término del título que, para esta investigación, se operacionaliza como una ocurrencia atendida y registrada por el patrullaje municipal e integrado (serenazgo y Patrullaje Local Integrado) en SIPCOP-M. Incluye hechos de distinta naturaleza; no todos son delitos: el 34 % de los registros es "exposición a peligro o abandono de personas", que probablemente corresponde a asistencia. Se definen dos conjuntos de análisis: el **principal**, con todo el extracto depurado, y el de **presuntos delitos**, que excluye esa modalidad y conserva las ocurrencias presuntamente contra el patrimonio y contra la vida, el cuerpo y la salud (unos 430 de 996 registros). La clasificación de cada modalidad se confirmará con la municipalidad.

Grupo espacial (clúster): conjunto de ocurrencias que DBSCAN o HDBSCAN agrupan por densidad. Es un resultado del algoritmo y, por sí solo, no implica que la concentración sea significativa.

Hotspot: grupo espacial cuyo número de ocurrencias supera lo esperado bajo aleatoriedad espacial completa, según el contraste de la sección 3.6.3.

3.2.3. Variables y operacionalización

Se trata de una investigación tecnológica cuyo artefacto es la arquitectura analítica y su prueba de concepto. No se plantea una relación experimental entre variables; los resultados de evaluación se organizan según los cuatro objetivos específicos (Tabla 2).

Tabla 2. *Operacionalización de los resultados medidos.*

Objetivo	Dimensión	Indicadores	Instrumento
OE1	Requisitos y perfil de datos	Campos disponibles, calidad, restricciones, reglas de validación y requisitos priorizados	Perfilado del extracto; matriz de requisitos
OE2	Diseño arquitectónico	Componentes, interfaces, flujo de datos, dependencias y trazabilidad	Vistas arquitectónicas; matriz requisito-componente
OE3	Funcionamiento de la prueba de concepto	Ejecución completa, registro de parámetros y exclusiones, tablas y mapas generados	Implementación local; casos funcionales
OE4	Calidad y reproducibilidad	Cumplimiento de requisitos, repetición con configuración constante, consistencia de salidas y tiempo de procesamiento	Matriz de aceptación; repetición controlada; medición de tiempo

Nota. Elaboración propia.

3.3. Unidad de análisis, población y muestra

3.3.1. Unidad de análisis

La unidad de análisis es la ocurrencia de seguridad ciudadana registrada en el SIPCOP-M, con su fecha, turno, tipo y ubicación. Los registros no tienen identificador único.

3.3.2. Población y muestra

La población accesible para este estudio está constituida por los 996 registros del extracto descargado de la capa SIPCOP Municipal, todos con `id_dist=080105` y fecha de alerta entre el 1 de enero y el 29 de agosto de 2025. Se realizará un censo de ese extracto, no una muestra probabilística. Este total describe el archivo disponible y no se interpreta como la totalidad de las ocurrencias realmente atendidas por el serenazgo.

Criterios de inclusión: registros dentro del periodo, con fecha, turno, categoría y coordenadas utilizables, y cuya ubicación corresponda al distrito tras validar el sistema de referencia. **Criterios de exclusión:** duplicados exactos (filas idénticas en los 19 campos; son 10, con lo que 996 pasa a 986), registros sin campos esenciales o con coordenadas fuera

del distrito. Como el archivo carece de identificador, los 70 registros con igual fecha, turno y coordenadas ("casi duplicados") no se eliminan, porque pueden ser hechos distintos en puntos recurrentes; se evalúa su efecto en el análisis de sensibilidad. El número de registros excluidos por cada criterio se informará (Anexo 3).

3.3.3. Diagnóstico preliminar del extracto

Antes del análisis se revisó el archivo descargado (Tabla 3). Este diagnóstico no contrasta ninguna hipótesis; sirve para fijar los parámetros del diseño con criterios explícitos.

Tabla 3. *Diagnóstico preliminar del extracto SIPCOP Municipal de San Sebastián.*

Aspecto	Hallazgo
Registros y periodo	996 filas, 19 columnas; 1/1–29/8/2025 (241 días, 215 con registro y 26 sin ningún registro)
Resolución espacial	Coordenadas en grados decimales con 3 decimales (unos 108 m en x y 111 m en y); 412 ubicaciones distintas; 765 registros (77 %) comparten coordenada exacta con otro
Duplicados	10 filas idénticas; 70 con igual fecha, turno y coordenadas; sin identificador único
Volumen mensual	Registros por día: 4,9 (ene.), 5,0 (feb.), 3,1 (mar.), 4,2 (abr.), 3,1 (may.), 2,0 (jun.), 3,5 (jul.) y 7,5 (ago., hasta el 29)
Cambio de clasificación	Exposición a peligro o abandono: 339 registros (34 %); 57 % de los registros de enero y 9–17 % de junio a agosto
Origen del registro	Patrullaje 760 (76 %); teléfono 216, alarma 13, mensajería 3; cámara, operativo y otros 4
Personal	Patrullaje Local Integrado 504 (51 %); Patrullaje Municipal – Serenazgo 492
Campos esenciales	`fechaalerta`, `turno`, `especifico`, `modalidad`, `x` e `y` sin valores nulos
Campos incompletos	`lugarocurrencia` 22 % faltante; `resultadoocurrencia` 67 % (casi solo en hechos contra la vida, el cuerpo y la salud); `consecuencia` 10 %; `medioutilizado` 32 % faltante y 64 % "OTROS"
Campos constantes	`generico`, `estado` e `id_dist`

Nota. Elaboración propia a partir del CSV SIPCOP Municipal (separador `;`, UTF-8 con BOM, fechas en texto en español, por ejemplo "agosto 23, 2025").

La Figura 2 muestra las 412 ubicaciones distintas: se concentran en dos franjas este–oeste y varias repiten la misma coordenada, lo que es coherente con una geocodificación

por puntos de referencia. La Figura 3 muestra que el volumen de registro y la proporción de la modalidad de exposición a peligro o abandono cambian entre meses. Ambas figuras son descriptivas y orientan la elección del radio ε y de la referencia temporal; no constituyen evidencia de concentración ni de patrón temporal alguno.

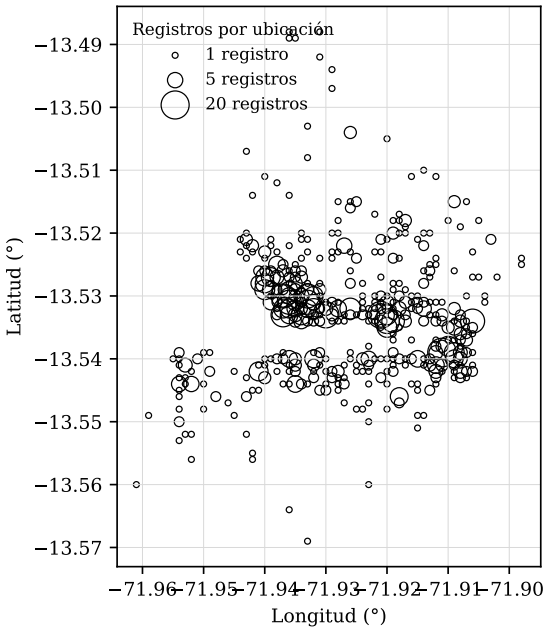


Figura 2. *Ubicaciones distintas del extracto SIPCOP Municipal (San Sebastián, 2025).*

Nota. Elaboración propia a partir del CSV SIPCOP Municipal. El tamaño del círculo es proporcional al número de registros con esa coordenada; $n = 996$ registros en 412 ubicaciones. Generada con `datos/figuras_diagnostico.py`.

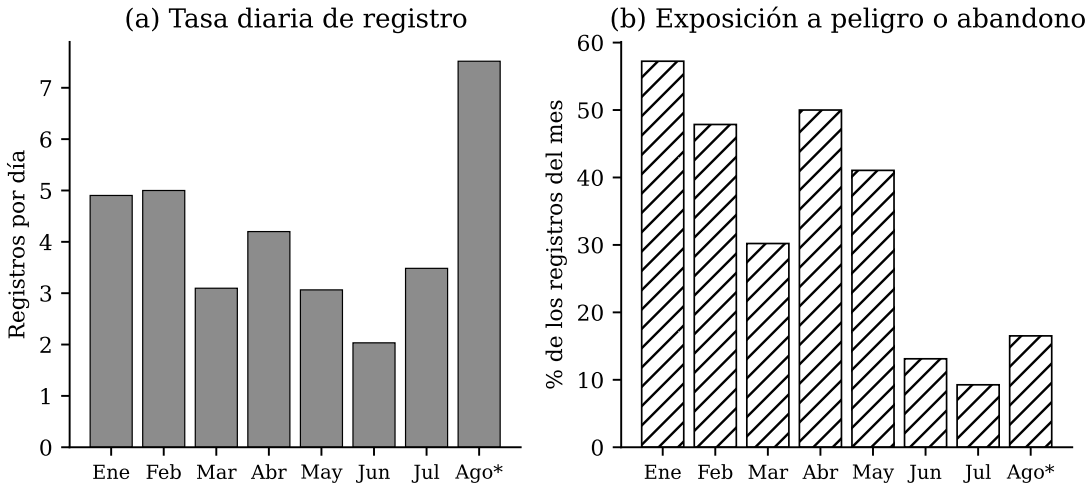


Figura 3. *Volumen de registro y modalidad de exposición a peligro o abandono por mes.*

Nota. Elaboración propia a partir del CSV SIPCOP Municipal. (*) Agosto incluye solo hasta el 29. En (a), la tasa es el número de registros dividido entre los días del mes observados; en (b), el porcentaje se calcula sobre los registros de cada mes.

3.4. Técnicas e instrumentos de recolección

- **Análisis documental:** revisión del archivo CSV público de la capa SIPCOP Municipal para el distrito `080105`; se conservarán la URL de origen, fecha de descarga y archivo original para trazabilidad. Se solicitará a la municipalidad o al responsable de la capa la definición de los campos y del sistema de referencia espacial.
- **Instrumento:** ficha de estructura de datos (Anexo 2), que documenta las 19 columnas del archivo. Los campos analíticos son `fechaalerta`, `turno`, `especifico`, `modalidad`, `x` e `y`; se usan además `origen`, `naturalezadelpersonal`, `lugarocurrencia`, `consecuencia`, `formapatrullaje`, `direccion` y `tipovia` para la calidad de datos y los análisis de sensibilidad. El archivo no contiene una hora individual del hecho.
- **Cartografía:** polígono oficial del distrito y, si está disponible, la capa de manzanas o vías, para delimitar el área de simulación.
- **Herramientas de análisis:** Python con las bibliotecas *pandas*, *scikit-learn* (Pedregosa et al., 2011), *hdbscan* (McInnes et al., 2017) y *SciPy*; un sistema de información geográfica para los mapas.

3.5. Procedimiento metodológico

1. **Especificación de requisitos.** Identificación de usuarios previstos, entradas, restricciones de datos y productos requeridos. Cada requisito funcional y de calidad se documentará con prioridad, criterio de aceptación y prueba asociada.
2. **Obtención y documentación.** Preservación del CSV disponible (996 registros; `id_dist=080105`) y registro de procedencia. Se consultará el significado de `fechaalerta`, los horarios de turno, las categorías y el sistema de referencia; las condiciones de reutilización se confirmarán antes de difundir resultados.
3. **Perfilado y validación de datos.** Revisión de duplicados, fechas, turnos, categorías y coordenadas; comprobación de que `x` sea longitud y y latitud, de la cuantización a 0,001°, del contraste entre `direccion` y coordenadas, y de la superposición con el polígono distrital. Se registrará cada fila procesada o excluida y su motivo. Si no se confirma la referencia espacial, no se interpretarán distancias ni agrupamientos métricos.
4. **Diseño de la arquitectura.** Especificación de componentes, responsabilidades, interfaces, formatos de entrada y salida, dependencias, errores controlados y trazabilidad, representados en vistas y en una matriz requisito-componente-prueba.
5. **Implementación de la prueba de concepto.** Construcción local de los módulos de ingesta, validación, preparación, análisis espacial y temporal y generación de productos. Se conservarán separados el archivo original, los datos preparados y los resultados de cada ejecución.
6. **Ejecución del caso.** Análisis exploratorio; aplicación de DBSCAN con distancia haversine (Algoritmo 1) y comparación con HDBSCAN; evaluación estadística de las concentraciones (sección 3.6.3); análisis temporal por turno, día de la semana y mes (sección 3.6.4); generación de tablas y mapas.
7. **Evaluación del artefacto.** Ejecución de casos de prueba válidos e inválidos, comprobación contra resultados de control, verificación de que ninguna fila quede sin estado documentado y repetición con datos, parámetros y semilla constantes. Los resultados se contrastarán con los criterios de aceptación fijados para la arquitectura.

8. **Revisión y comunicación.** Revisión de la interpretación de resultados con personal municipal si se obtiene su colaboración, documentación de limitaciones y presentación de la arquitectura, pruebas y resultados agregados.

Algoritmo 1. DBSCAN aplicado a las ocurrencias georreferenciadas.

1. Inicializar $C \leftarrow 0$ y marcar todos los puntos como no visitados.
2. Para cada punto $p \in D$ no visitado: marcarlo como visitado y calcular su vecindario $N_\varepsilon(p)$ con la distancia d (ecuación 1).
3. Si $|N_\varepsilon(p)| <$ MinPts, etiquetar p como ruido.
4. En caso contrario, crear un nuevo grupo C, asignar p a dicho grupo y expandirlo con todos los puntos alcanzables dentro del radio ε.
5. Repetir hasta que todos los puntos queden etiquetados como pertenecientes a un grupo o como ruido.

3.6. Protocolo de evaluación

3.6.1. Selección de parámetros y calidad del agrupamiento

En DBSCAN, épsilon define el radio de vecindad y MinPts el mínimo de puntos requerido para formar una región densa. La estabilidad de las particiones se compara mediante el índice de Rand ajustado (*Adjusted Rand Index*) (ARI).

La regla de selección se fija antes de ver los resultados de los contrastes. Las coordenadas tienen resolución de 0,001° (unos 108–111 m): dos puntos de celdas distintas distan al menos ese paso, de modo que con $\varepsilon \leq 100$ m solo se agrupan registros con coordenada idéntica, y $\varepsilon = 50$ y 100 m producen la misma partición (diagnóstico preliminar). Por ello se explora una rejilla de $\varepsilon \in \{150, 200, 250, 300\}$ m y MinPts $\in \{10, 20, 30\}$, y el gráfico de k-distancias orienta el rango de ε. Los registros con coordenadas idénticas cuentan como puntos separados al evaluar MinPts. Para cada configuración se calculan el número de grupos, el porcentaje de ruido y la silueta media (ecuación 4) sobre los puntos asignados. Se elige la configuración con mayor estabilidad, medida como el índice de Rand ajustado promedio (ARI) (Hubert & Arabie, 1985) entre sus asignaciones y las de las configuraciones vecinas de la rejilla, entre las que tengan al menos dos grupos, menos de 60 % de ruido y

ningún grupo que reúna más de 25 % de los registros depurados o supere 1 km de diámetro, para que no domine un grupo único formado por encadenamiento. La silueta no decide la elección y se interpreta con cautela, porque los puntos coincidentes (distancia cero) y la malla de coordenadas la distorsionan. Se presentará además el análisis de sensibilidad con las demás configuraciones.

3.6.2. Comparación entre DBSCAN y HDBSCAN

Se compararán las asignaciones de ambos algoritmos mediante el ARI, el número de grupos, el porcentaje de ruido y la coincidencia de los grupos grandes (los centroides a menos de ε de distancia). Para HDBSCAN se variará el tamaño mínimo de grupo en un rango análogo a MinPts. La comparación es descriptiva: no se declara un algoritmo "correcto", sino en qué zonas coinciden y en cuáles difieren.

3.6.3. Concentración espacial frente al azar

El modelo nulo de referencia es la aleatoriedad espacial completa (CSR): n puntos independientes y uniformes dentro del **polígono real del distrito**, con el mismo n que los datos depurados. La CSR es la referencia mínima, no un contraste exigente: casi cualquier ciudad rechaza la uniformidad porque la población, las vías y el comercio no se reparten de manera uniforme. Por eso se añade un **segundo modelo nulo**: la simulación restringida al área urbanizada (manzanas o vías) y, para los análisis por tipo de ocurrencia, la simulación con intensidad proporcional a la densidad kernel de todas las ocurrencias del extracto (de modo que se pregunte si un tipo se concentra más que el conjunto). Se informan los resultados bajo ambos nulos.

Se simulan $B = 999$ conjuntos y a cada uno se le aplica el agrupamiento con los parámetros ya elegidos para los datos reales, tras redondear las coordenadas simuladas a la misma rejilla de 0,001°; de lo contrario los datos reales parecerían más densos que el azar solo por la cuantización. El estadístico es el tamaño m_j de cada grupo observado j. Su valor p se calcula contra el tamaño del mayor grupo de cada simulación, M_b, lo que controla el

error en las comparaciones entre grupos:

$$p_j = \frac{1 + \#\{\, b : M_b \geq m_j \,\}}{1 + B} \tag{6}$$

Un grupo con $p_j < \alpha$ se considera un *hotspot*. La comparación global (número de puntos en grupos frente a lo simulado) se informa como apoyo para H_1. Esta prueba se limita a comparar con una distribución uniforme: no distingue entre concentración por mayor actividad delictiva y concentración por mayor población, vías o presencia de patrullaje.

3.6.4. Distribución temporal de los *hotspots*

Para cada *hotspot* se compara la distribución de sus ocurrencias según fecha de alerta (día de la semana y mes) y turno con la del resto del distrito, es decir, con las ocurrencias que no pertenecen a ese *hotspot*. La referencia principal es la prueba chi-cuadrado de homogeneidad (ecuación 5) sobre la tabla de contingencia *hotspot* frente a resto por categoría temporal; cuando más del 20 % de las frecuencias esperadas sea menor que 5 se usa una prueba de permutación (Cochran, 1954). Esta referencia absorbe la variación del volumen de registro entre meses, que es grande en el extracto (de 2,0 registros diarios en junio a 7,5 en agosto) y que no se debe a ningún *hotspot* en particular.

Como **análisis secundario** se contrasta, mediante chi-cuadrado de bondad de ajuste, si cada *hotspot* sigue la distribución esperada por exposición calendario:

- **Turno:** proporcional a las horas de cada turno según la organización real del patrullaje (se pedirá a la municipalidad).
- **Día de la semana:** proporcional al número de veces que ocurre cada día calendario entre el 1 de enero y el 29 de agosto de 2025.
- **Mes:** proporcional al número de días observados de cada mes, incluidos enero y agosto parciales.

Como la tasa mensual de registro cambia tanto, esta referencia se rechazará casi con seguridad aun sin concentración espacial alguna; se informa pero no sustenta por sí sola H_2. Además, 26 de los 241 días no tienen registro y se desconoce si hubo cero eventos o falta de reporte; los contrastes se repiten sobre días con registro y sobre todos los días. El cambio

de clasificación de “exposición a peligro o abandono” entre meses se controla repitiendo los contrastes sin esa modalidad (sección 3.6.5).

Los contrastes suponen un riesgo constante en el tiempo y no prueban causalidad. Para evaluar si los *hotspots* difieren entre sí en su distribución temporal se usa además la prueba chi-cuadrado de independencia sobre la tabla *hotspot* por categoría temporal, con el tamaño del efecto medido mediante el coeficiente V de Cramér:

$$V = \sqrt{\frac{\chi^2}{n \,\text{mín}(r-1, c-1)}} \tag{7}$$

donde n es el total de ocurrencias y r y c el número de filas y de columnas de la tabla de contingencia.

3.6.5. Análisis de sensibilidad

Los resultados principales se repiten en cuatro variantes para valorar su robustez: (i) solo registros de origen ciudadano o de alarma (teléfono, alarma y mensajería; 232 registros), que dependen menos de dónde patrulla el personal; se declara de antemano que, por ser pocos registros, solo admitirán valores bajos de MinPts; (ii) el conjunto de presuntos delitos, sin la modalidad de exposición a peligro o abandono, por su cambio de clasificación entre meses; (iii) sin los 70 casi duplicados (misma fecha, turno y coordenadas); y (iv) con un desplazamiento aleatorio uniforme de ± 55 m en las coordenadas, que aproxima el error por redondeo. Una conclusión se considera robusta solo si se mantiene en la mayoría de las variantes.

3.7. Métodos de análisis de datos

Se emplea estadística descriptiva (frecuencias, porcentajes, medidas de tendencia central) y las pruebas descritas arriba, con $\alpha = 0{,}05$. Como se contrastarán varios *hotspots* y tres variables temporales, los valores p de los contrastes temporales se ajustarán por comparaciones múltiples (corrección de Holm). Se fijará la semilla aleatoria y se versionarán los *scripts* para garantizar la reproducibilidad.

3.8. Aspectos éticos y de gestión de datos

El estudio utiliza registros administrativos disponibles públicamente y se ajustará a la Ley de Protección de Datos Personales (Congreso de la República del Perú, 2011) y a las condiciones de uso de la fuente. Se emplearán solo los campos necesarios (`fechaalerta`, `turno`, `especifico` o `modalidad`, coordenadas), sin nombres ni documentos personales. Antes de publicar resultados se confirmarán las condiciones de reutilización con la entidad responsable; los resultados se agregarán por grupo y los mapas evitarán identificar domicilios concretos. El archivo de trabajo se almacenará de forma segura y se utilizará únicamente con fines de investigación.

CAPÍTULO IV

ESTUDIO DE FACTIBILIDAD

4.1. Enfoque adoptado

El proyecto comprende la especificación de una arquitectura analítica y una prueba de concepto local con datos que la municipalidad ya produce y herramientas de código abierto. No contempla despliegue institucional, servicios en la nube ni adquisición de equipamiento especializado. La factibilidad se analiza en sus dimensiones técnica, económica y operativa.

4.2. Factibilidad técnica

4.2.1. Hardware y cómputo

El volumen disponible (996 registros de un distrito para enero-agosto de 2025) es manejable en un computador personal de gama media. El prototipo podrá integrar preparación de datos, DBSCAN/HDBSCAN, simulación Monte Carlo (999 repeticiones) y generación de mapas en ese equipo; se medirán tiempos y recursos como parte de la evaluación, sin extrapolarlos a volúmenes institucionales mayores.

4.2.2. Datos

El CSV SIPCOP Municipal ya está disponible y se realizó un diagnóstico preliminar (Tabla 3): los 996 registros no tienen valores nulos en fecha, turno, tipo ni coordenadas, las coordenadas están en grados decimales con resolución de unos 110 m (412 ubicaciones distintas) y el volumen de registro varía de 2,0 a 7,5 por día entre meses. Los riesgos principales son la interpretación de `fechaalerta`, la ausencia de un diccionario que defina el sistema de referencia de `x` e `y`, la definición de las categorías y el cambio de clasificación entre meses. Se mitigarán documentando la fuente, consultando a la entidad responsable en las primeras semanas y traduciendo estas limitaciones en requisitos, validaciones y criterios de aceptación (objetivos específicos 1 y 2). Si no se confirma la referencia espacial, se limitará

el procesamiento a resultados que no dependan de distancias y se registrará esa restricción en la arquitectura.

4.2.3. Herramientas y software

Se emplearán Python y sus bibliotecas de ciencia de datos (*pandas*, *scikit-learn*, *hdbscan*, *SciPy*), un sistema de información geográfica de código abierto para los mapas y LaTeX para la redacción. La prueba de concepto se ejecutará localmente y sus módulos, dependencias, parámetros y entradas/salidas quedarán documentados. Todas las herramientas son de uso libre.

4.3. Factibilidad económica

El presupuesto estimado (Tabla 5) asciende a S/ 1 220,00, compuesto por gastos de servicios, materiales y trámites; al no requerir hardware ni licencias adicionales, es asumible con recursos propios.

4.4. Factibilidad operativa

El extracto público permite iniciar el análisis sin esperar una nueva entrega de datos. Se procurará la colaboración de la Municipalidad Distrital de San Sebastián para validar las definiciones de los campos, los horarios de turno y, de ser posible, interpretar los *hotspots*; también se verificarán las condiciones de reutilización y difusión. El estudio no implica intervención sobre personas ni trabajo de campo extenso.

4.5. Viabilidad y sostenibilidad

La arquitectura y el flujo de la prueba de concepto podrán reproducirse con otros extractos que cumplan el contrato de datos documentado. Su adaptación a nuevos periodos o distritos requerirá validar la calidad, el sistema de referencia y las categorías de cada fuente; el uso de herramientas libres favorece esa adaptación, pero el mantenimiento y despliegue municipal quedan fuera del alcance.

CAPÍTULO V

ASPECTOS ADMINISTRATIVOS

5.1. Cronograma de actividades

El proyecto se ejecuta en 16 semanas, entre el 19 de octubre de 2026 y el 7 de febrero de 2027. La Tabla 4 presenta el diagrama de Gantt.

Tabla 4. *Cronograma de actividades por semanas (octubre 2026 – febrero 2027).*

	Oct				Nov				Dic				Ene			Feb
Actividad	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
Aprobación del plan de tesis	■	■														
Solicitud de autorización y acceso a datos	■	■	■	■												
Reunión con la municipalidad (CRS, fecha de alerta, turnos, categorías)	■	■														
Revisión del estado del arte	■	■	■	■												
Especificación de requisitos y criterios de aceptación			■	■												
Diseño de componentes, interfaces y flujo arquitectónico					■	■	■									
Depuración y validación espacial del extracto					■	■	■									
Implementación de la prueba de concepto							■	■	■	■						
Agrupamiento, contrastes y salidas cartográficas								■	■	■	■					
Pruebas funcionales, reproducibilidad y evaluación										■	■	■	■			
Redacción del informe final											■	■	■	■	■	
Sustentación															■	■

Nota. Elaboración propia. Cada columna es una semana; la semana 1 inicia el 19 de octubre de 2026.

5.2. Presupuesto y financiamiento

La Tabla 5 resume los recursos estimados, que serán financiados con recursos propios del tesista.

Tabla 5. *Presupuesto estimado del proyecto (soles).*

Rubro	Descripción	Costo (S/)
Servicios	Acceso a Internet durante cuatro meses	240,00
Materiales	Papel, impresiones y anillado de ejemplares	300,00
Trámites	Inscripción, derechos y trámites administrativos de la tesis	400,00
Movilidad	Traslados a la Municipalidad Distrital y a reuniones con el asesor	180,00
Imprevistos	Gastos no previstos	100,00
Total		**1 220,00**

Nota. Elaboración propia. Los montos son estimaciones y se actualizarán con las tarifas vigentes.

5.3. Equipo de investigación

Tabla 6. *Equipo de investigación.*

Rol	Responsable y función
Tesista	Br. Ronaldo Ticona Jancco: diseño, ejecución del análisis y redacción.
Asesor	Por designar: orientación metodológica y técnica.
Colaboradores	Personal de la Municipalidad Distrital de San Sebastián (acceso a datos y validación de los *hotspots*).

Nota. Elaboración propia.

REFERENCIAS

Argotti, Y., Kenfaoui, Y., Baron, C., Abran, A., & Esteban, P. (2024). An operational quality model of embedded software aligned with ISO 25000. *ACM Transactions on Embedded Computing Systems*, *24*(1), 1-41. https://doi.org/10.1145/3691642

Barata, J., da Cunha, P. R., & de Figueiredo, A. D. (2023). Self-reporting limitations in information systems design science research. *Business & Information Systems Engineering*, *65*(2), 143-160. https://doi.org/10.1007/s12599-022-00782-8

Campello, R. J. G. B., Moulavi, D., & Sander, J. (2013). Density-based clustering based on hierarchical density estimates. *Advances in Knowledge Discovery and Data Mining (PAKDD 2013)*, 160-172.

Cardone, B., & Di Martino, F. (2022). Fuzzy-based spatiotemporal hot spot intensity and propagation: An application in crime analysis. *Electronics*, *11*(3), 370. https://doi.org/10.3390/electronics11030370

Chainey, S., & Ratcliffe, J. (2005). *GIS and Crime Mapping*. Wiley.

Chainey, S., Tompson, L., & Uhlig, S. (2008). The utility of hotspot mapping for predicting spatial patterns of crime. *Security Journal*, *21*(1–2), 4-28.

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide* (inf. téc.). SPSS Inc.

Choi, C., & Hong, S.-Y. (2021). MDST-DBSCAN: A density-based spatial clustering method for multidimensional spatiotemporal data clustering. *ISPRS International Journal of Geo-Information*, *10*(6), 391. https://doi.org/10.3390/ijgi10060391

Cochran, W. G. (1954). Some methods for strengthening the common χ^2 tests. *Biometrics*, *10*(4), 417-451.

Cohen, L. E., & Felson, M. (1979). Social change and crime rate trends: A routine activity approach. *American Sociological Review*, *44*(4), 588-608.

Congreso de la República del Perú. (2003). Ley N.º 27933, Ley del Sistema Nacional de Seguridad Ciudadana.

Congreso de la República del Perú. (2011). Ley N.º 29733, Ley de Protección de Datos Personales.

Cramér, H. (1946). *Mathematical Methods of Statistics*. Princeton University Press.

Cutid-Aguero, J., Alarcon-Ventura, K., Canales-Escalante, C., Huaman-Yrigoin, D., Zarate-Bocanegra, J.-A., Solis-Tipian, M., & Zevallos-Vera, E. (2025). Spatial-temporal analysis and characterization of crime in the Constitutional Province of Callao, February 2024: An approach based on spatial data mining. *5th LACCEI International Multiconference on Entrepreneurship, Innovation and Regional Development (LEIRD 2025)*.

Eck, J. E., Chainey, S., Cameron, J. G., Leitner, M., & Wilson, R. E. (2005). *Mapping Crime: Understanding Hot Spots* (inf. téc.). National Institute of Justice.

Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD-96)*, 226-231.

Gustriansyah, R., Alie, J., & Suhandi, N. (2022). Hierarchical clustering for crime rate mapping in Indonesia. *ILKOM Jurnal Ilmiah*, *14*(3), 275-283. https://doi.org/10.33096/ilkom.v14i3.1135.275-283

Hajela, G., Chawla, M., & Rasool, A. (2020). A clustering-based hotspot identification approach for crime prediction. *Procedia Computer Science*, *167*, 1462-1470. https://doi.org/10.1016/j.procs.2020.03.357

Hernández-Sampieri, R., & Mendoza, C. P. (2018). *Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta*. McGraw-Hill.

Hu, Y., Wang, F., Guin, C., & Zhu, H. (2018). A spatio-temporal kernel density estimation framework for predictive crime hotspot mapping and evaluation. *Applied Geography*, *99*, 89-97.

Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification*, *2*(1), 193-218.

Instituto Nacional de Estadística e Informática. (2023). Encuesta Nacional de Programas Presupuestales (ENAPRES) [Informe técnico, periodo noviembre 2022-abril 2023].

International Organization for Standardization. (2023). ISO/IEC 25010:2023 Systems and software engineering—Systems and software Quality Requirements and Evaluation (SQuaRE)—Product quality model. *ISO*.

International Organization for Standardization & Institute of Electrical and Electronics Engineers. (2022). ISO/IEC/IEEE 42010:2022 Systems and software engineering—Architecture description. *ISO/IEC/IEEE*.

Knox, E. G. (1964). The detection of space-time interactions. *Journal of the Royal Statistical Society. Series C (Applied Statistics)*, *13*(1), 25-29.

Kulldorff, M. (1997). A spatial scan statistic. *Communications in Statistics – Theory and Methods*, *26*(6), 1481-1496.

Mamani Ramos, Y. L. (2019). *Sistema de geo-sectorización de la inseguridad ciudadana para la sectorización de zonas delictivas en el contexto turístico utilizando algoritmos de clustering* [Tesis de grado]. Universidad Peruana Unión [Repositorio institucional UPeU. http://repositorio.upeu.edu.pe/handle/20.500.12840/2114].

Masron, T., Nordin, M. N., Yaakub, N. F., & Jubit, N. (2021). Spatial analysis of crime hotspot in the Northeast Penang Island District and Kuching District, Malaysia. *PLANNING MALAYSIA*, *19*. https://doi.org/10.21837/pm.v19i19.1057

McInnes, L., Healy, J., & Astels, S. (2017). hdbscan: Hierarchical density based clustering. *Journal of Open Source Software*, *2*(11), 205.

Medina Ariza, J., & Solymosi, R. (2023a). Detecting hot spots and repeats. En *Crime Mapping and Spatial Data Analysis using R* (pp. 271-298). CRC Press. https://doi.org/10.1201/9781003154914-10

Medina Ariza, J., & Solymosi, R. (2023b). Spatial point patterns of crime events. En *Crime Mapping and Spatial Data Analysis using R* (pp. 179-204). CRC Press. https://doi.org/10.1201/9781003154914-7

Medina Ariza, J., & Solymosi, R. (2023c). Time matters. En *Crime Mapping and Spatial Data Analysis using R* (pp. 157-178). CRC Press. https://doi.org/10.1201/9781003154914-6

Pearson, K. (1900). On the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling. *Philosophical Magazine, Series 5*, *50*(302), 157-175.

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830.

Peffers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, *24*(3), 45-77. https://doi.org/10.2753/MIS0742-1222240302

Policía Nacional del Perú. (2024). Denuncias por homicidio, departamento de Cusco, 2022-2024 [Estadística de denuncias, enero-noviembre de 2024].

Ratcliffe, J. H. (2004). Geocoding crime and a first estimate of a minimum acceptable hit rate. *International Journal of Geographical Information Science*, *18*(1), 61-72.

Ripley, B. D. (1976). The second-order analysis of stationary point processes. *Journal of Applied Probability*, *13*(2), 255-266.

Ristea, A., & Leitner, M. (2020). Urban crime mapping and analysis using GIS. *ISPRS International Journal of Geo-Information*, *9*(9), 511. https://doi.org/10.3390/ijgi9090511

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, *20*, 53-65.

Schäffer, T., & Leyh, C. (2025). Holistic evaluations in design science research: A framework for systematic selection of evaluation method and effective artifact evaluation. En *Lecture Notes in Business Information Processing* (pp. 155-175). Springer. https://doi.org/10.1007/978-3-031-93580-0_7

Schubert, E., Sander, J., Ester, M., Kriegel, H.-P., & Xu, X. (2017). DBSCAN revisited, revisited: Why and how you should (still) use DBSCAN. *ACM Transactions on Database Systems*, *42*(3), 19:1-19:21.

Sherman, L. W., Gartin, P. R., & Buerger, M. E. (1989). Hot spots of predatory crime: Routine activities and the criminology of place. *Criminology*, *27*(1), 27-56.

Silverman, B. W. (1986). *Density Estimation for Statistics and Data Analysis*. Chapman; Hall.

Sinnott, R. W. (1984). Virtues of the haversine. *Sky and Telescope*, *68*(2), 159.

Weigand, H., & Johannesson, P. (2023). How to identify your design science research artifact. *2023 IEEE 25th Conference on Business Informatics*, 1-10. https://doi.org/10.1109/CBI58679.2023.10187511

Weigand, H., Johannesson, P., & Andersson, B. (2021). An artifact ontology for design science research. *Data & Knowledge Engineering*, *133*, 101878. https://doi.org/10.1016/j.datak.2021.101878

Weisburd, D. (2015). The law of crime concentration and the criminology of place. *Criminology*, *53*(2), 133-157. https://doi.org/10.1111/1745-9125.12070

Xie, Y., Jia, X., Shekhar, S., Bao, H., & Zhou, X. (2021). Significant DBSCAN+: Statistically robust density-based clustering. *ACM Transactions on Intelligent Systems and Technology*, *12*(5), 1-26. https://doi.org/10.1145/3474842

Anexo 1

Matriz de consistencia

Tabla 7. *Matriz de consistencia.*

Problema	**Objetivo**	**Hipótesis**	**Técnica**
General: ¿cómo debe estructurarse y evaluarse una arquitectura basada en clústeres espaciales para caracterizar los incidentes registrados en SIPCOP-M?	Desarrollar y evaluar una arquitectura analítica mediante una prueba de concepto reproducible	H_G (sección 1.3)	Especificación arquitectónica, pruebas funcionales y evaluación del caso
PE1: requisitos funcionales, de datos y calidad requeridos por el extracto SIPCOP-M	OE1: analizar las características y calidad del extracto y especificar requisitos de arquitectura	H_1	Perfilado de datos y trazabilidad de requisitos
PE2: componentes, interfaces y flujo para integrar procesamiento espacial y temporal	OE2: diseñar arquitectura, componentes, interfaces, flujo de datos y trazabilidad	H_2	Modelado arquitectónico y matriz requisito-componente
PE3: implementación reproducible del flujo arquitectónico y resultados generados	OE3: implementar una prueba de concepto con preparación de datos, DBSCAN/HDBSCAN, análisis y cartografía	H_3	Casos de prueba y ejecución repetida
PE4: cumplimiento de requisitos y criterios de calidad definidos	OE4: evaluar la arquitectura y la prueba de concepto	H_4	Matriz de aceptación, pruebas funcionales, consistencia de salidas y tiempo de procesamiento

Nota. Elaboración propia.

Anexo 2

Ficha de estructura de datos del SIPCOP-M

Tabla 8. *Campos del archivo CSV SIPCOP Municipal (19 columnas).*

Campo del CSV	Tipo	Descripción observada	Uso previsto
`fechaalerta`	Texto (fecha)	Fecha de alerta en español (“agosto 23, 2025”); semántica por confirmar	Día de semana, mes; conversión a fecha
`turno`	Categórica	Mañana, tarde, noche	Análisis temporal
`especifico`	Categórica	8 categorías (vida, cuerpo y salud; patrimonio; etc.)	Descripción, conjuntos por tipo
`modalidad`	Categórica	Modalidad presunta (por ejemplo, exposición a peligro o abandono, robo a personas)	Conjunto de presuntos delitos
`generico`	Categórica	Valor único: alertas tempranas en apoyo a la PNP	Delimita el extracto
`origen`	Categórica	Patrullaje, teléfono, alarma, WhatsApp, cámara, operativo, otros	Sensibilidad por origen
`naturalezadelpersonal`	Categórica	Patrullaje Local Integrado o Patrullaje Municipal – Serenazgo	Descripción y terminología
`formapatrullaje`	Categórica	Motorizado, a pie, bicicleta, otros	Descripción
`lugarocurrencia`	Categórica	Vía pública, inmueble particular, otros; 22 % faltante	Calidad de datos
`resultadoocurrencia`	Categórica	Consumado o frustrado; 67 % faltante	Calidad de datos
`consecuencia`	Categórica	Ninguno, materiales, lesiones, etc.; 10 % faltante	Calidad de datos
`medioutilizado`	Categórica	32 % faltante y 64 % “OTROS”	Calidad de datos
`tipovia`	Categórica	Calle, avenida, pasaje, jirón; 175 “SIN DATO”	Descripción
`direccion`	Texto libre	Dirección o punto de referencia; 5 “SIN DATO”	Contraste con coordenadas
`estado`, `estadoocurrencia`	Categórica	`estado` constante (activo); casi todos cerrados	Verificación
`id_dist`	Código	080105 en todo el extracto	Verificación del ámbito
`x`	Numérica (texto)	Longitud en grados decimales, 3 decimales (unos 108 m)	Análisis espacial tras validar
`y`	Numérica (texto)	Latitud en grados decimales, 3 decimales (unos 111 m)	Análisis espacial tras validar

Nota. Campos observados en el CSV disponible (separador `;`, codificación UTF-8 con BOM, saltos de línea CRLF, coordenadas entre comillas). La definición de categorías, el significado de la fecha de alerta y el sistema de referencia se confirmarán con la entidad responsable.

Anexo 3

Registro de depuración de datos

Tabla 9. *Registro de depuración preliminar.*

Etapa	Registros restantes	Registros excluidos
Registros del CSV disponible (1/1–29/8/2025)	996	—
Tras eliminar duplicados exactos	986	10
Con `fechaalerta` y turno válidos	986	0
Con coordenadas presentes y parseables	986	0
Con CRS validado y ubicación dentro del distrito	Por completar	Por completar
Registros utilizables para el análisis	Por completar (máximo 986)	Por completar

Nota. Conteos del diagnóstico preliminar. Los 70 registros con igual fecha, turno y coordenadas no se excluyen (ver sección 3.3.2). Falta verificar la ubicación frente al polígono distrital.