UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO
Facultad de Ingeniería Eléctrica, Electrónica, Informática y Mecánica



PLAN DE TESIS

Arquitectura de clústeres espaciales
para la caracterización de incidentes de seguridad ciudadana en San Sebastián, Cusco

Tesista: Ronaldo Ticona Jancco
Asesor: Por designar

Cusco – Perú
2026

Ruta de la exposición

Problema y propósito

- Contexto y brecha local
- Pregunta, objetivos e hipótesis
- Aporte esperado

Diseño y ejecución

- Datos y procedimiento
- Agrupamiento y contrastes
- Ética, factibilidad y cronograma

Contexto: seguridad ciudadana en Cusco

92,3 %

percepción de inseguridad en Cusco

ENAPRES, nov. 2022–abr. 2023

36 → 60

denuncias por homicidio en Cusco

2022 → ene.–nov. 2024

Por qué importa el lugar

- Los hechos **no se distribuyen de manera uniforme**.
- Identificar la **concentración espacial y temporal** puede orientar el patrullaje.
- Los indicadores departamentales **no describen** los patrones dentro de San Sebastián.

Fuentes citadas en el plan: PNP (2024); INEI–ENAPRES (2023); Sherman et al. (1989); Weisburd (2015).

Problema de investigación

El SIPCOP-M registra ocurrencias atendidas por el patrullaje municipal e integrado, pero **no se han analizado integralmente en sus dimensiones espacial y temporal** para reconocer concentraciones y recurrencias.

Brecha de información

- Datos tabulares **sin análisis geoespacial** documentado.
- **Calidad y cobertura** de fecha, tipo y ubicación por verificar.

Consecuencia para la gestión

- Es difícil identificar **zonas y momentos** de mayor recurrencia.
- Se limita la **focalización del patrullaje** con evidencia local.

996
registros en el extracto SIPCOP-M

1 ene–29 ago
de 2025 (`fechaalerta`, por validar)

$\sim$110 m
resolución de las coordenadas

Pregunta de investigación

Pregunta general

¿Cómo debe estructurarse y evaluarse una arquitectura basada en clústeres espaciales para caracterizar los incidentes registrados en SIPCOP-M?

- ¿Qué requisitos funcionales, de datos y de calidad debe atender la arquitectura?
- ¿Qué componentes, interfaces y flujo integran el procesamiento espacial y temporal?
- ¿Cómo implementar una prueba de concepto reproducible y evaluar su cumplimiento?

Objetivos e hipótesis

Objetivo general

Desarrollar y evaluar una arquitectura analítica basada en clústeres espaciales mediante una prueba de concepto reproducible.

Objetivos específicos

1. Especificar requisitos a partir del extracto SIPCOP-M.
2. Diseñar componentes, interfaces, flujo y trazabilidad.
3. Implementar la prueba de concepto con DBSCAN/HDBSCAN, análisis y cartografía.
4. Evaluar requisitos, reproducibilidad y calidad de resultados.

Hipótesis de trabajo

HG: la arquitectura permitirá ejecutar un flujo trazable y reproducible conforme a requisitos y criterios de aceptación.

H1–H4: requisitos trazables, componentes completos, ejecución reproducible y cumplimiento de criterios.

Las concentraciones significativas son resultados del caso, no condición de éxito de la arquitectura.

Justificación y delimitación

Aporte

- Arquitectura lógica con componentes, interfaces y trazabilidad.
- Prueba de concepto reproducible con validación y análisis espacial.
- Criterios de aceptación para evaluar funcionamiento y calidad.

Alcance

- Distrito de San Sebastián, Cusco.
- Extracto disponible: 1/1/2025 al 29/8/2025 (996 registros).
- Artefacto local; no es una plataforma municipal en producción.
- El caso usa ocurrencias registradas, no todos los incidentes ocurridos.

Antecedentes y conceptos clave

Antecedentes

- Sherman et al. (1989): concentración de hechos en pocos lugares.
- Weisburd (2015): regularidad de la concentración en microlugares.
- Cutid-Aguero et al. (2025): aplicación peruana de densidad kernel y DBSCAN.

Brecha local

La revisión preliminar no identificó una arquitectura documentada que integre validación de datos SIPCOP-M, agrupamiento espacial, evaluación estadística, análisis temporal y resultados reproducibles para San Sebastián.

La búsqueda de antecedentes sobre arquitectura y estudios locales debe completarse antes de la sustentación.

¿Qué se va a identificar?



Ocurrencia

Hecho **atendido y registrado** por el patrullaje municipal e integrado. No necesariamente es un delito (34 % es exposición a peligro o abandono) ni representa todos los hechos ocurridos.



Clúster

Grupo de puntos que el **algoritmo** reúne por **densidad espacial**.



Hotspot

Clúster cuya concentración **supera el patrón esperado** bajo el modelo nulo definido.

Un clúster algorítmico no es automáticamente un hotspot estadístico.

Métodos de agrupamiento espacial

DBSCAN: método principal

- Agrupa **puntos densos** dentro de un radio ε.
- **Parámetros:** ε y MinPts.
- Permite grupos de formas diversas y puntos aislados como **ruido**.

HDBSCAN: comparación

- Explora **jerarquías de densidad**.
- No requiere un **único** ε **fijo**.
- Se compararán asignaciones, ruido y estabilidad.

La densidad kernel se empleará solo como visualización complementaria, no como prueba de significancia. (Ester et al., 1996; Campello et al., 2013; McInnes et al., 2017.)

Diseño metodológico

Enfoque y tipo

Cuantitativo y tecnológico; investigación aplicada con construcción y evaluación de un artefacto.

Diseño

Construcción y evaluación de artefacto; caso de aplicación retrospectivo con fechas de alerta del 1/1 al 29/8 de 2025.

Proceso

Requisitos, arquitectura, prueba de concepto, pruebas funcionales y evaluación; análisis de datos basado en CRISP-DM.

Unidad del caso: cada ocurrencia registrada por el patrullaje municipal e integrado.

Datos requeridos y población

Población y selección

- **Censo** de los **996 registros** del extracto SIPCOP Municipal disponible para el distrito.
- Fechas de alerta: 1/1/2025 al 29/8/2025; el extracto no representa otros periodos.
- Se validarán definiciones de campos y condiciones de reutilización.

Campos por ocurrencia

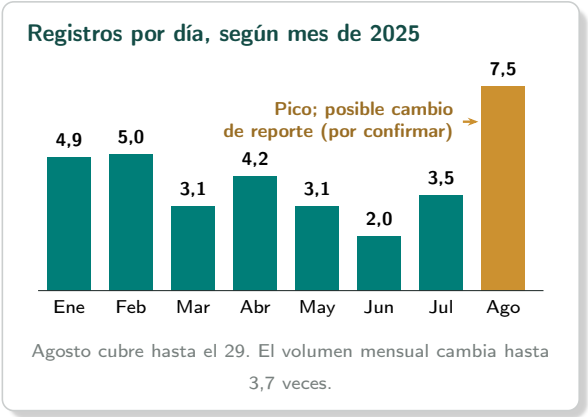
19 columnas. Analíticas: `fechaalerta`, `turno`, `especifico`, `modalidad`, `x`, `y`; de apoyo: `origen`, `naturalezadelpersonal`, `direccion`. Sin hora individual ni identificador único.

Apoyos solicitados

Diccionario de datos, horarios de turnos, polígono distrital y, si existe, cobertura de patrullaje.

Solicitar también registros incompletos para medir calidad. No se requieren nombres, DNI ni teléfonos.

Diagnóstico preliminar del extracto



- **996 registros**; 215 de 241 días con registro.
- Coordenadas a 0,001° ($\sim$110 m): **412 ubicaciones**; 77 % comparte punto con otro registro.
- "Exposición a peligro o abandono": **34 %** del total; 57 % en enero y 9–17 % de junio a agosto.
- 76 % nace del patrullaje; 232 de llamadas, alarmas o mensajería.
- 51 % es Patrullaje Local Integrado.
- **10 duplicados exactos** y 70 casi duplicados.

Implicación para el diseño: ε parte de **150 m** y la referencia temporal es el perfil del resto del distrito.

Calidad de datos y criterios

Inclusión en el análisis espacial

- **Fecha y tipo** utilizables.
- **Coordenadas válidas** dentro del distrito.
- **Sistema de referencia** espacial conocido.

Control de calidad

- **Duplicados** y **campos faltantes**.
- **Fechas fuera del periodo** y **puntos fuera del polígono**.
- **Resolución de coordenadas** (0,001°), **dirección frente a coordenadas** y polígono distrital; **cambio de categorías** entre meses.

Se informará cuántos registros se excluyen y por qué.

Construcción y evaluación de la arquitectura



Perfilar el extracto y priorizar requisitos verificables.	**Especificar** componentes, interfaces y trazabilidad.	**Implementar** el flujo local de validación y agrupamiento.	**Ejecutar** contrastes espaciales y caracterización temporal.	**Verificar** aceptación, repetibilidad y productos generados.

Herramientas previstas: Python (pandas, scikit-learn, hdbscan, SciPy) y un SIG de código abierto; prototipo no desplegado en producción.

Parámetros y evaluación de DBSCAN

Búsqueda inicial definida en el plan

$$\varepsilon \in \{150, 200, 250, 300\} \text{ m}, \qquad \text{MinPts} \in \{10, 20, 30\}$$

- Con coordenadas a 0,001° ($\sim$110 m), $\varepsilon = 50$ **y** 100 **m dan la misma partición**; por eso la rejilla parte de **150 m**. Los puntos coincidentes cuentan por separado para MinPts.
- Se registrarán **número de grupos, porcentaje de ruido y silueta** (con cautela por los puntos coincidentes).
- La configuración se elegirá por **estabilidad** (ARI promedio frente a configuraciones vecinas) entre soluciones admisibles: al menos 2 grupos, menos de 60 % de ruido y ningún grupo con más de 25 % de los registros ni 1 km de diámetro.
- Se reportará **sensibilidad** a las demás configuraciones y **comparación con HDBSCAN**.

La regla se fijará antes de interpretar los resultados.

Contraste espacial: ¿más concentración que por azar?

Modelo nulo

Aleatoriedad espacial completa (CSR): n puntos uniformes e independientes dentro del polígono distrital.

- **Simulación Monte Carlo:** $B = 999$ simulaciones.
- Se repite el agrupamiento con los parámetros elegidos, redondeando los puntos simulados a la rejilla de 0,001°.
- **Segundo nulo:** área urbanizada (manzanas o vías). La CSR es solo la referencia mínima.

Decisión por grupo j

Se compara el tamaño observado m_j con el mayor grupo simulado M_b:

$$p_j = \frac{1 + \#\{b : M_b \geq m_j\}}{1 + B}.$$

Los grupos que superen el contraste se denominarán ***hotspots***.

Análisis temporal

Qué se comparará

Distribución de cada hotspot por **turno, día de la semana y mes** frente al resto del distrito (**chi-cuadrado de homogeneidad** o permutación).

Análisis secundario: exposición calendario

- Turno: horas de operación de cada turno.
- Día: cantidad de cada día en el periodo.
- Mes: número de días de cada mes. Se rechazará casi siempre: la tasa mensual va de 2,0 a 7,5 registros por día.

Pruebas y reporte

- **Homogeneidad o permutación** como referencia principal; bondad de ajuste como secundaria.
- **Ajuste de Holm** por comparaciones múltiples.
- **V de Cramér** como tamaño del efecto.

Sensibilidad: solo registros ciudadanos (232), sin exposición a peligro o abandono, sin casi duplicados y con desplazamiento de ± 55 m. Los contrastes no prueban causalidad.

Ética, límites y resultados esperados

Ética y límites

- Usar solo campos necesarios, con datos anonimizados.
- Presentar mapas agregados; evitar identificar domicilios.
- El registro describe lo atendido, no todo lo ocurrido.
- El 76 % nace del patrullaje: se medirá el sesgo con los registros ciudadanos. Además, resolución de $\sim$110 m, 26 días sin registro y cambio de clasificación entre meses.

Productos esperados

- Diagnóstico de calidad de la base.
- Mapas y caracterización de grupos espaciales.
- Comparación DBSCAN/HDBSCAN y análisis temporal.
- Procedimiento y scripts reproducibles.

Los resultados se obtendrán durante la ejecución; no se anticipan aquí.

Factibilidad y cronograma

Factibilidad

- Equipo personal y software libre.
- El volumen previsto es manejable.
- Condición crítica: reunión temprana con la municipalidad (CRS, fecha de alerta, turnos).
- Presupuesto estimado: S/ 1 220,00.

16 semanas: oct. 2026–feb. 2027

Actividad	Periodo previsto
Reunión municipal y autorización	Sem. 1–4
Depuración y exploración	Sem. 3–7
Agrupamiento y contrastes	Sem. 7–11
Mapas y validación	Sem. 10–13
Informe y sustentación	Sem. 11–16

Referencias clave y preguntas

- Campello, R. et al. (2013). Density-based clustering based on hierarchical density estimates.
- Chapman, P. et al. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*.
- Ester, M. et al. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise.
- McInnes, L. et al. (2017). *hdbscan: Hierarchical density based clustering*.
- Sherman, L. et al. (1989). Hot spots of predatory crime.
- Weisburd, D. (2015). The law of crime concentration and the criminology of place.

También se consultarán PNP, INEI–ENAPRES, MININTER–OBNASEC y la normativa peruana citada en el plan.

Gracias

Preguntas y comentarios

Br. Ronaldo Ticona Jancco